session intensive deep learning

Adrien CHAN-HON-TONG
ONERA

Introduction

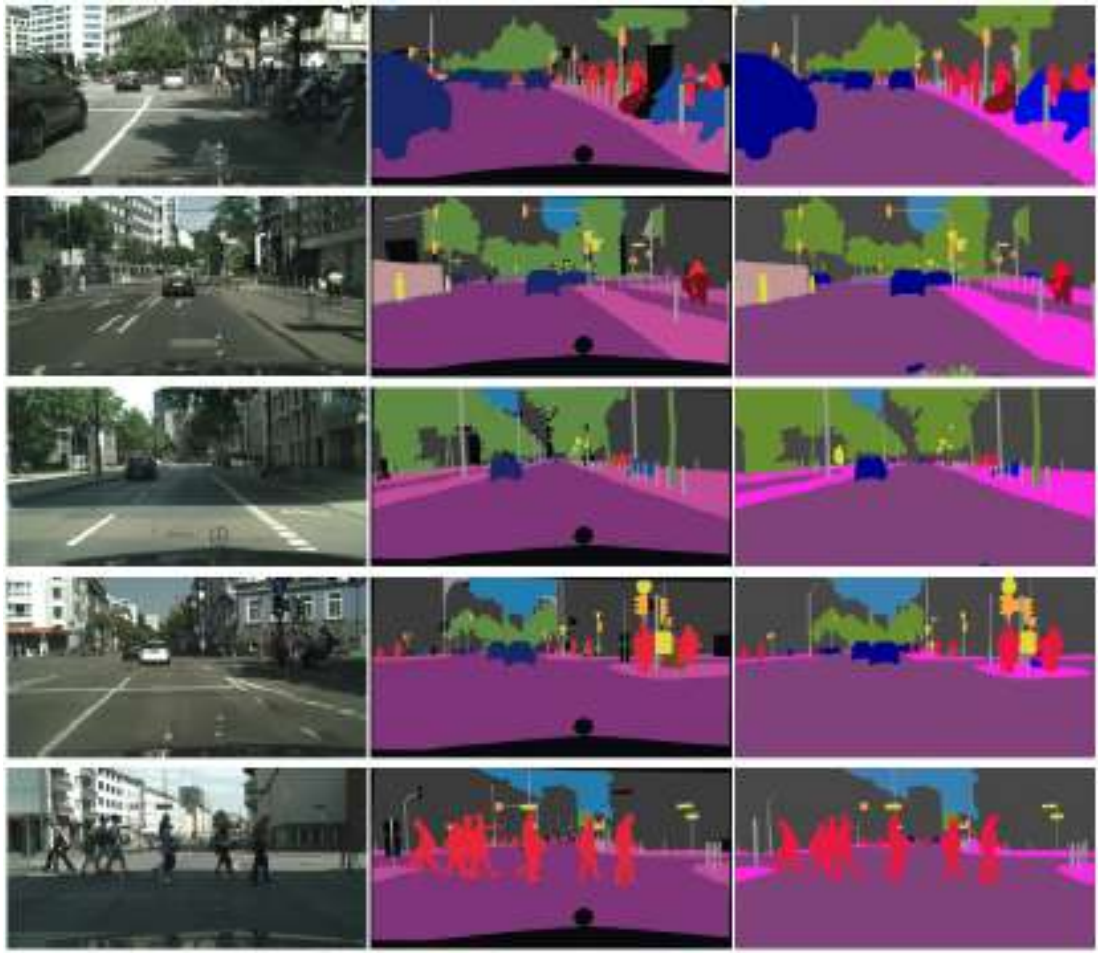

Introduction

Introduction

Avant le deep learning

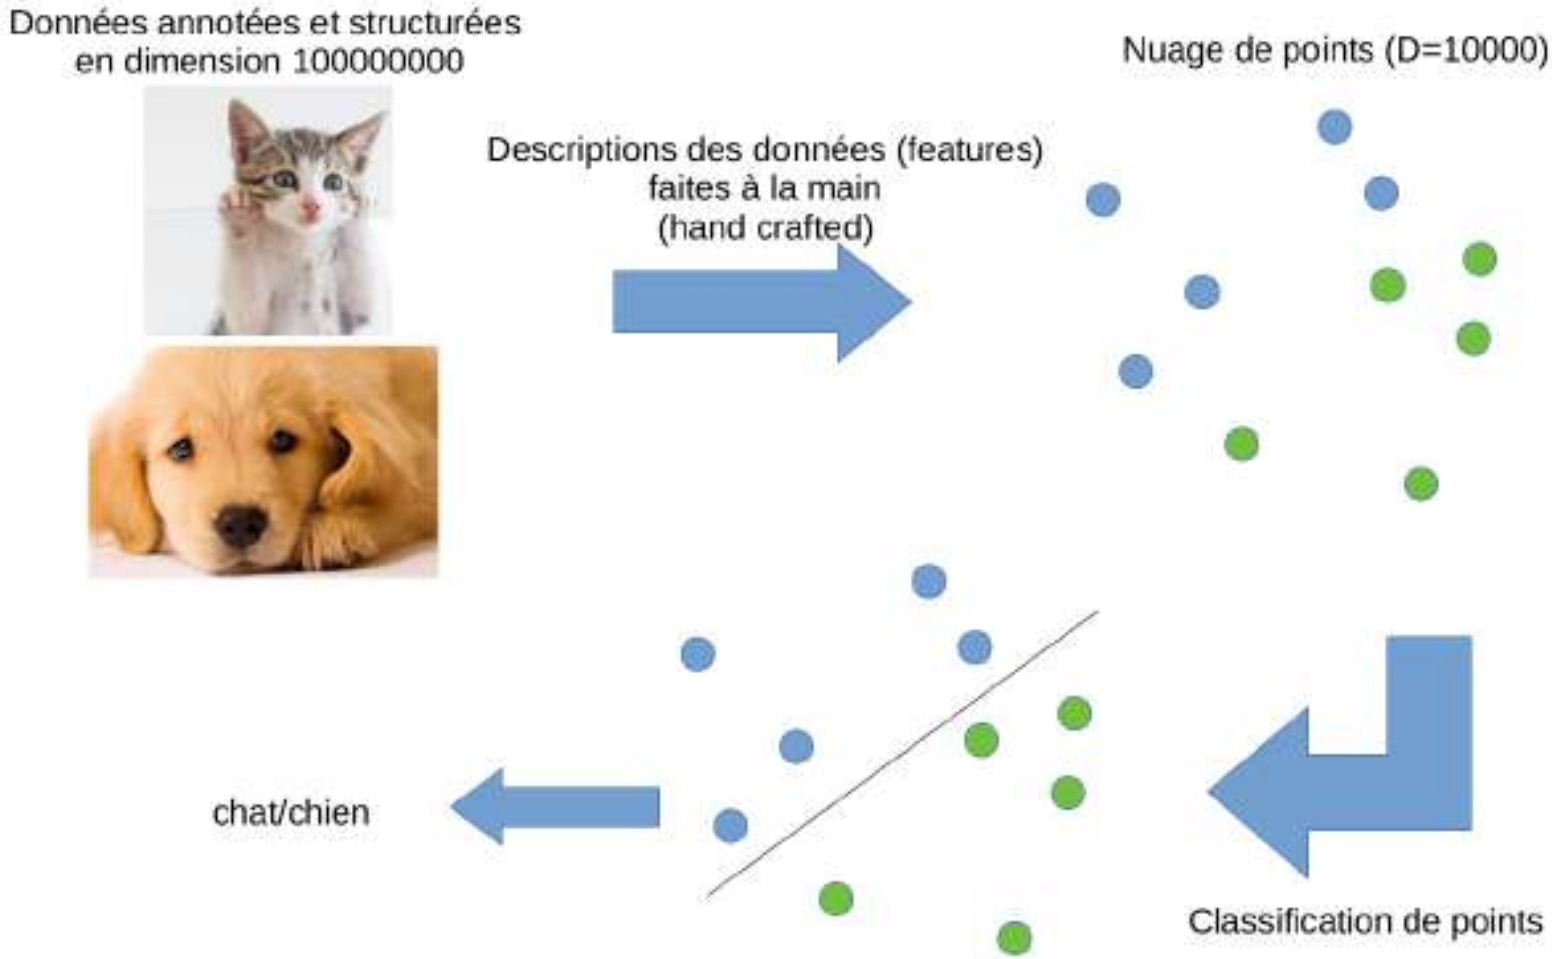

Introduction

Après

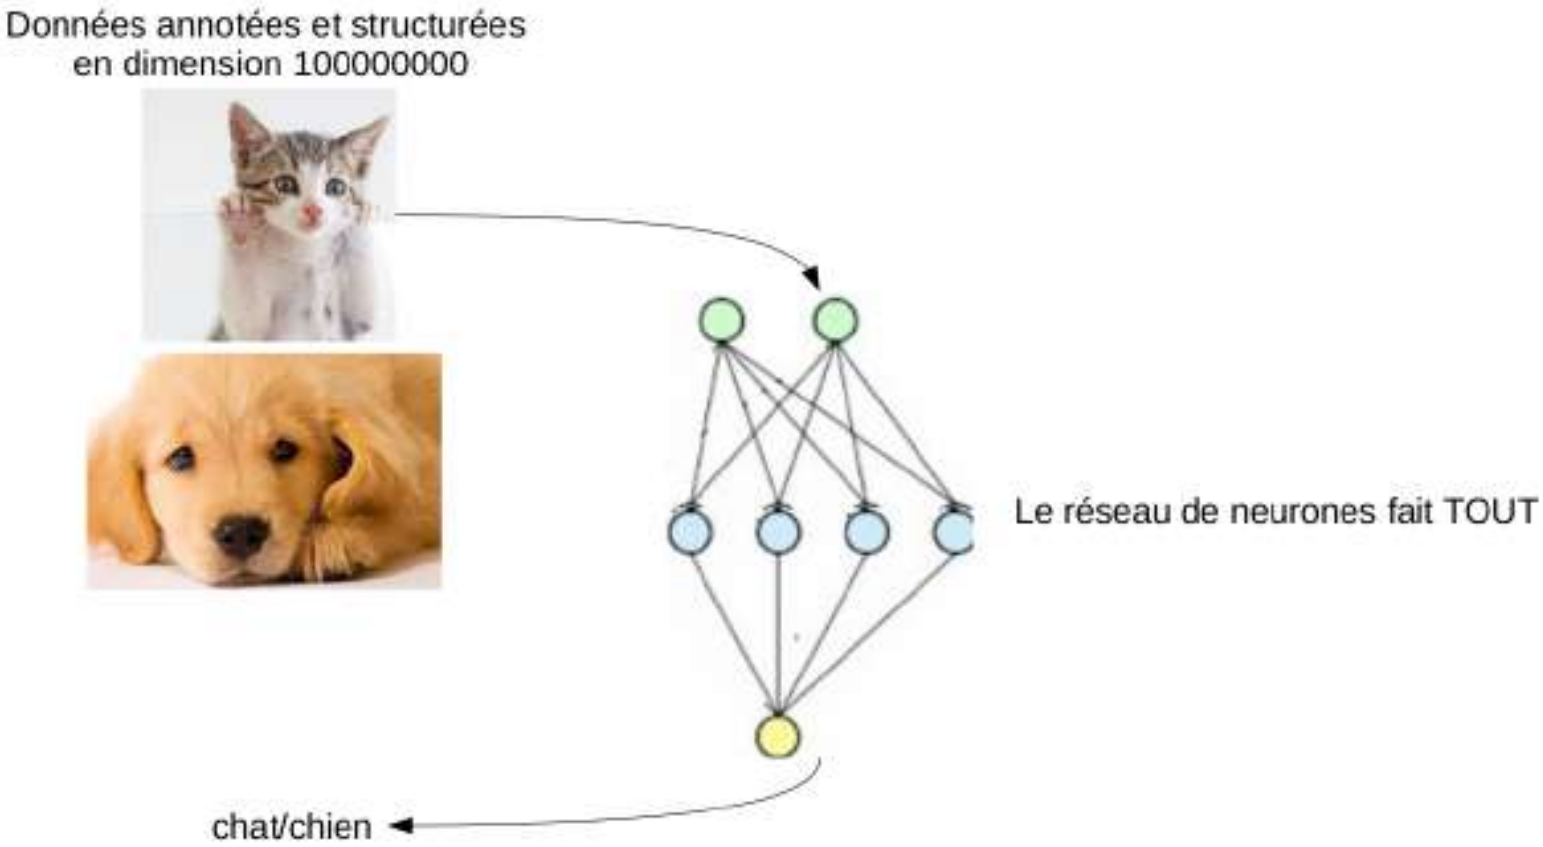

Introduction

Important

Le deep learning n'est pas vraiment supérieur à d'autres algorithmes (forêt de décision, XGboost ...) sur la classification de **points**.

Le deep learning est par contre incontournable pour le traitement de données structurées (son, image, vidéo, texte, signal 1D...)

Plan

- Classification de points
  - Apprentissage et test
  - Neurone et réseau
  - Universalité et erreur de généralisation
- Double descente
  - Compromis simplicité/complexité
  - Méthodes par ensemble, double descente
  - Descente de gradient Stochastique
- Traitement de données structurées
  - Neurones convolutif
  - Détection, segmentation, génération...
  - Problème de stabilité

2 phases

Apprentissage

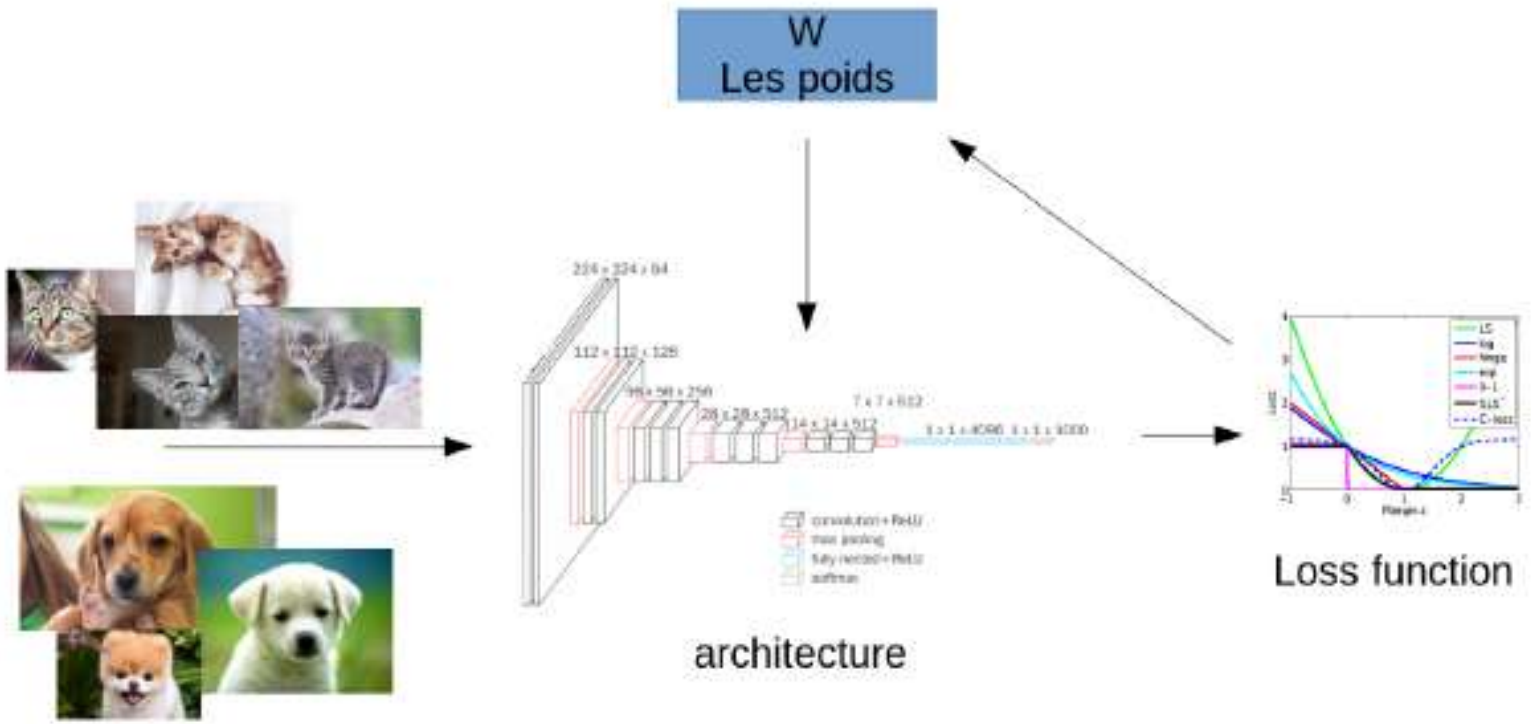

2 phases

Test et/ou production et/ou inférence

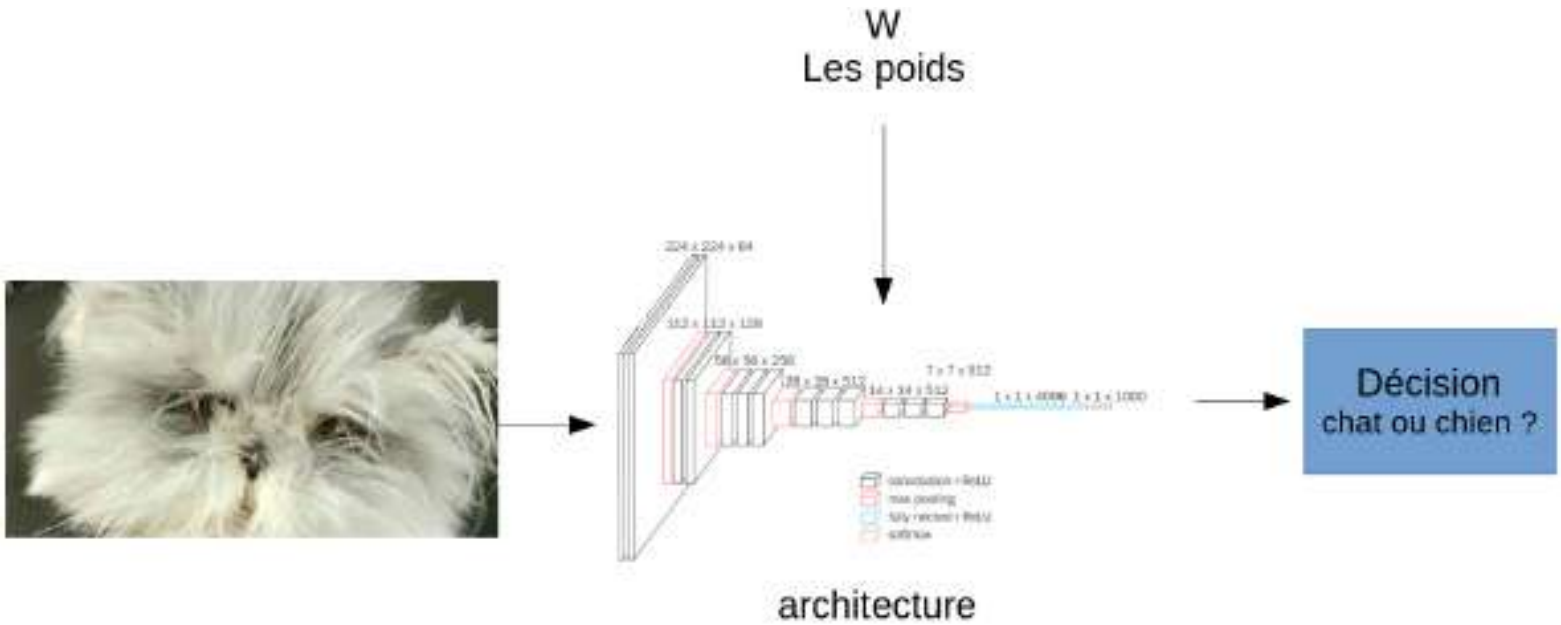

2 phases

Important

Il est essentiel de bien avoir en tête le problème global

L'optimisation des poids w est un problème difficile.

Mais il n'a de sens que dans l'ensemble : choix d'une architecture, chois d'une fonction de coût, et objectif de performance en test.

Plan

- Classification de points
  - Apprentissage et test
  - Neurone et réseau
  - Universalité et erreur de généralisation
- Double descente
  - Compromis simplicité/complexité
  - Méthodes par ensemble, double descente
  - Descente de gradient Stochastique
- Traitement de données structurées
  - Neurones convolutif
  - Détection, segmentation, génération...
  - Problème de stabilité

Apprentissage d'une séparation hyperplane

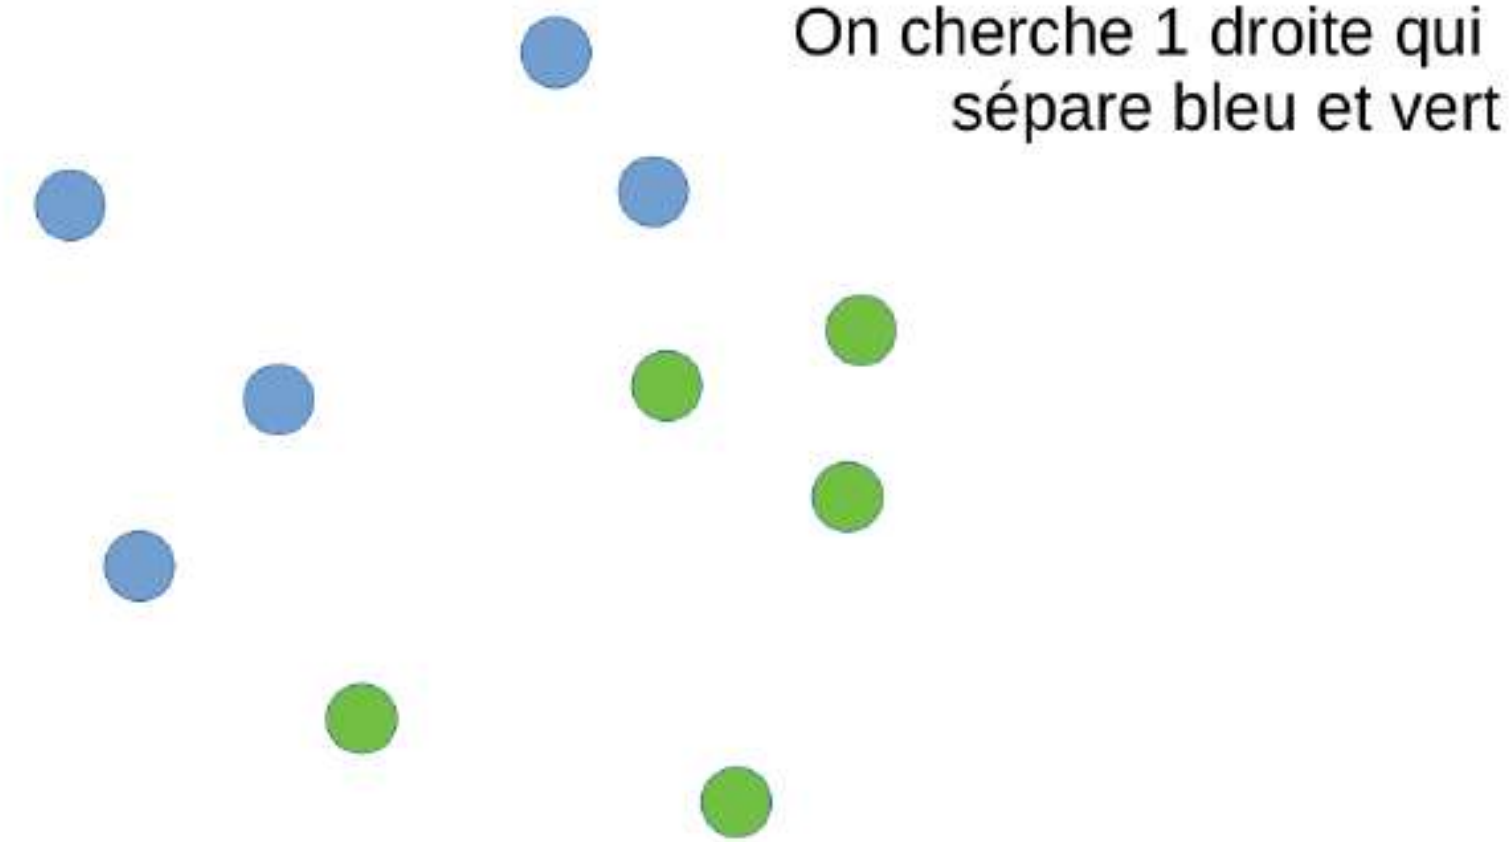

Apprentissage d'une séparation hyperplane

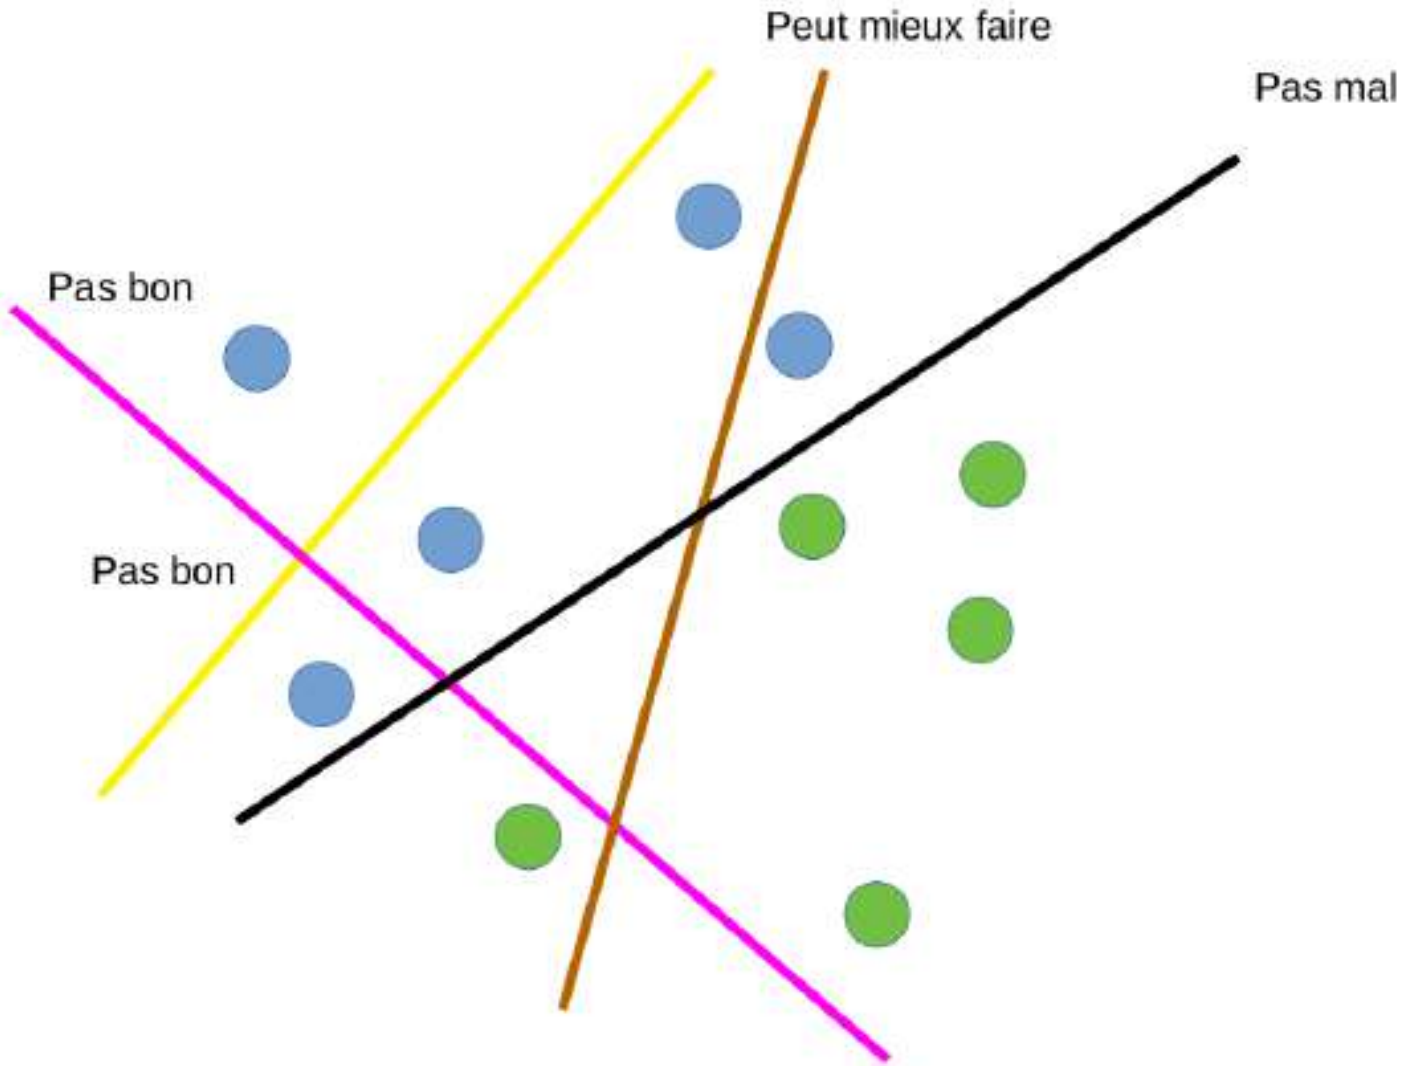

Apprentissage d'une séparation hyperplane

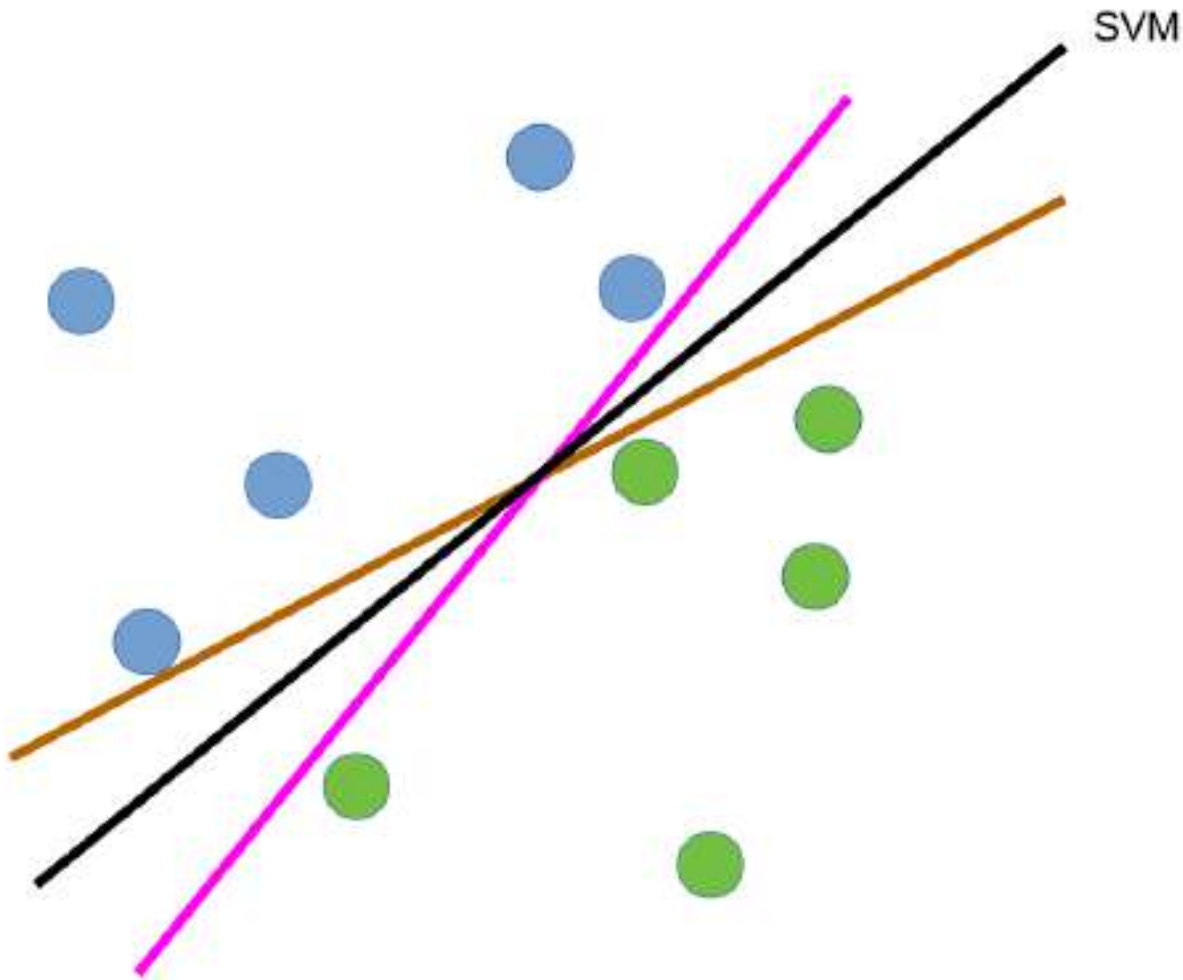

Apprentissage d'une séparation hyperplane

Qu'est ce que ça donne avec des maths ?

On a des points $x_1, ..., x_N \in \mathbb{R}^D$ avec une couleur (bleu ou pas bleu) $(y_1, ..., y_N) \in \{-1, 1\}^N$.
Et on cherche un plan qui sépare les points.

Apprentissage d'une séparation hyperplane

Rappel de math

On peut le paramétrer par un vecteur normal $w \in \mathbb{R}^D$ et un bias $b \in \mathbb{R}$. L'équation du plan est $w^T x + b = 0$.
Le plan sépare alors l'espace en 2 : $\{x \ / \ w^T x + b > 0\}$ et $\{x \ / \ w^T x + b < 0\}$.

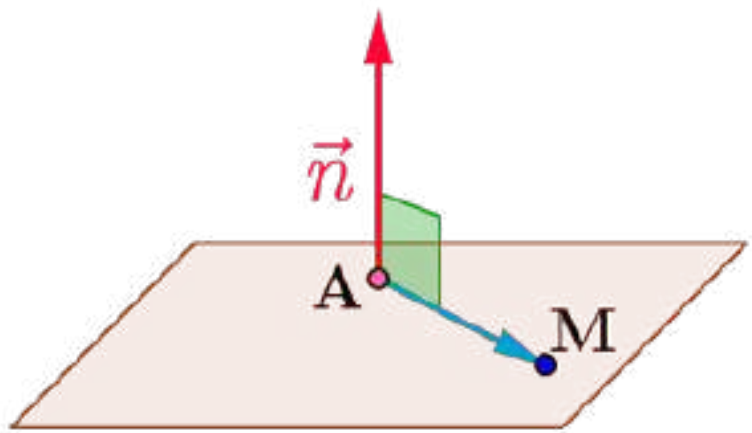

ici $w = \vec{n}$, M est dans le plan car $\vec{n}.\vec{AM} = 0$, si $\vec{n}.\vec{AM} > 0$ on est au dessus et sinon en dessous.

Apprentissage d'une séparation hyperplane

Linear feasibility

On a des points $x_1, ..., x_N \in \mathbb{R}^D$ avec une couleur (bleu ou pas bleu) $(y_1, ..., y_N) \in \{-1, 1\}^N$.
Et on cherche un plan w, b tel que $y_n = 1 \rightarrow w^T x_n + b > 0$ et $y_n = -1 \rightarrow w^T x_n + b < 0$, ce qu'on peut résumer en

$$\forall n \in \{1, ..., M\},\ y_n(w^T x_n + b) > 0$$

Apprentissage d'une séparation hyperplane

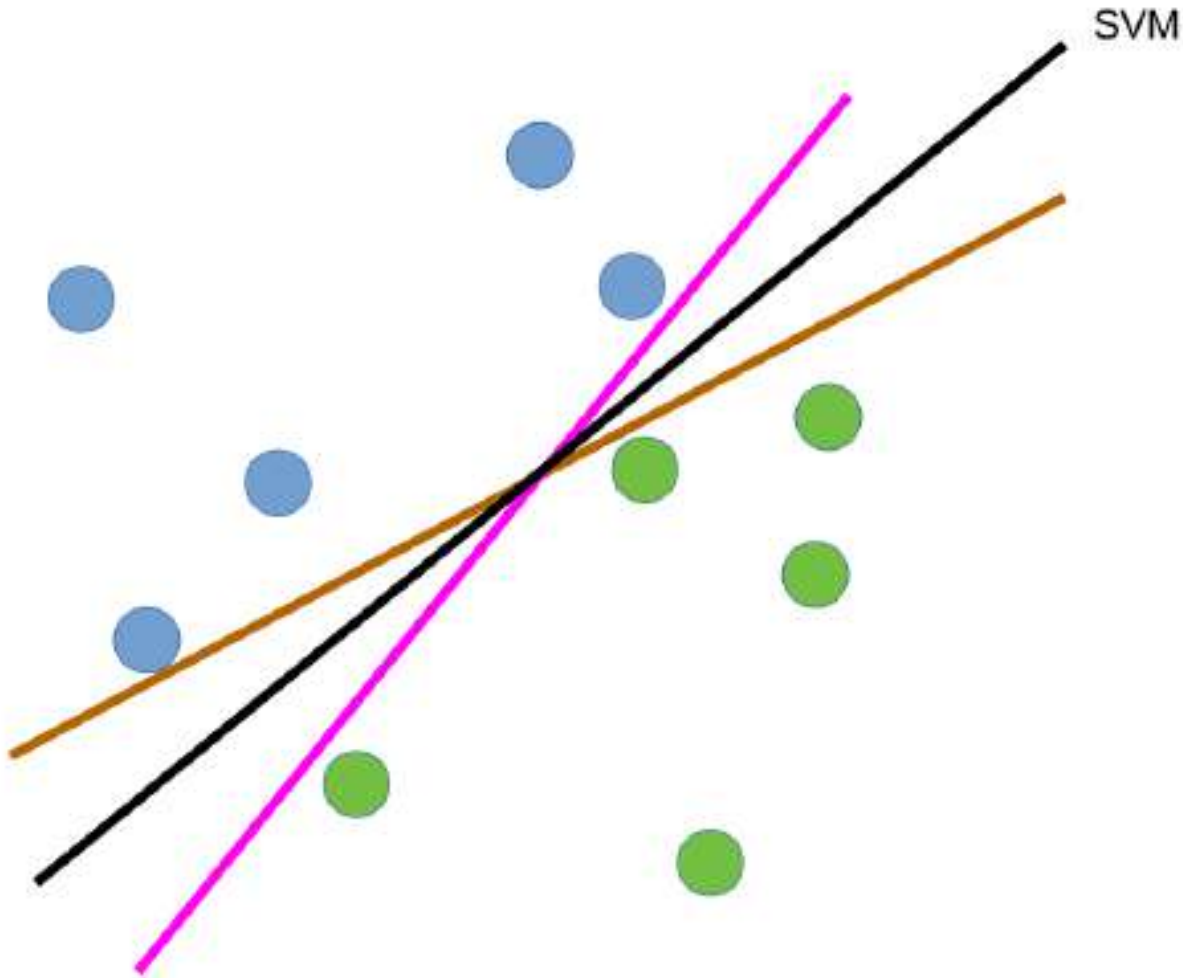

Apprentissage d'une séparation hyperplane

SVM

On a des points $x_1, ..., x_N \in \mathbb{R}^D$ avec une couleur (bleu ou pas bleu) $(y_1, ..., y_N) \in \{-1, 1\}^N$.
Et le plan w, b qui sépare les points en étant le plus distant possible

$$\max_{w,b,\delta} \delta$$

$$sc : \forall n \in \{1, ..., M\},\ y_n(w^T x_n + b) > \delta$$

$$sc : w^T w = 1$$

Apprentissage d'une séparation hyperplane

SVM

On a des points $x_1, ..., x_N \in \mathbb{R}^D$ avec une couleur (bleu ou pas bleu) $(y_1, ..., y_N) \in \{-1, 1\}^N$.
Et le plan w, b qui sépare les points en étant le plus distant possible

$$\min_{w,b} w^T w$$

$$sc : \forall n \in \{1, ..., M\},\ y_n(w^T x_n + b) \geq 1$$

Problème

Parfois on ne peut PAS séparer les données avec un hyperplan

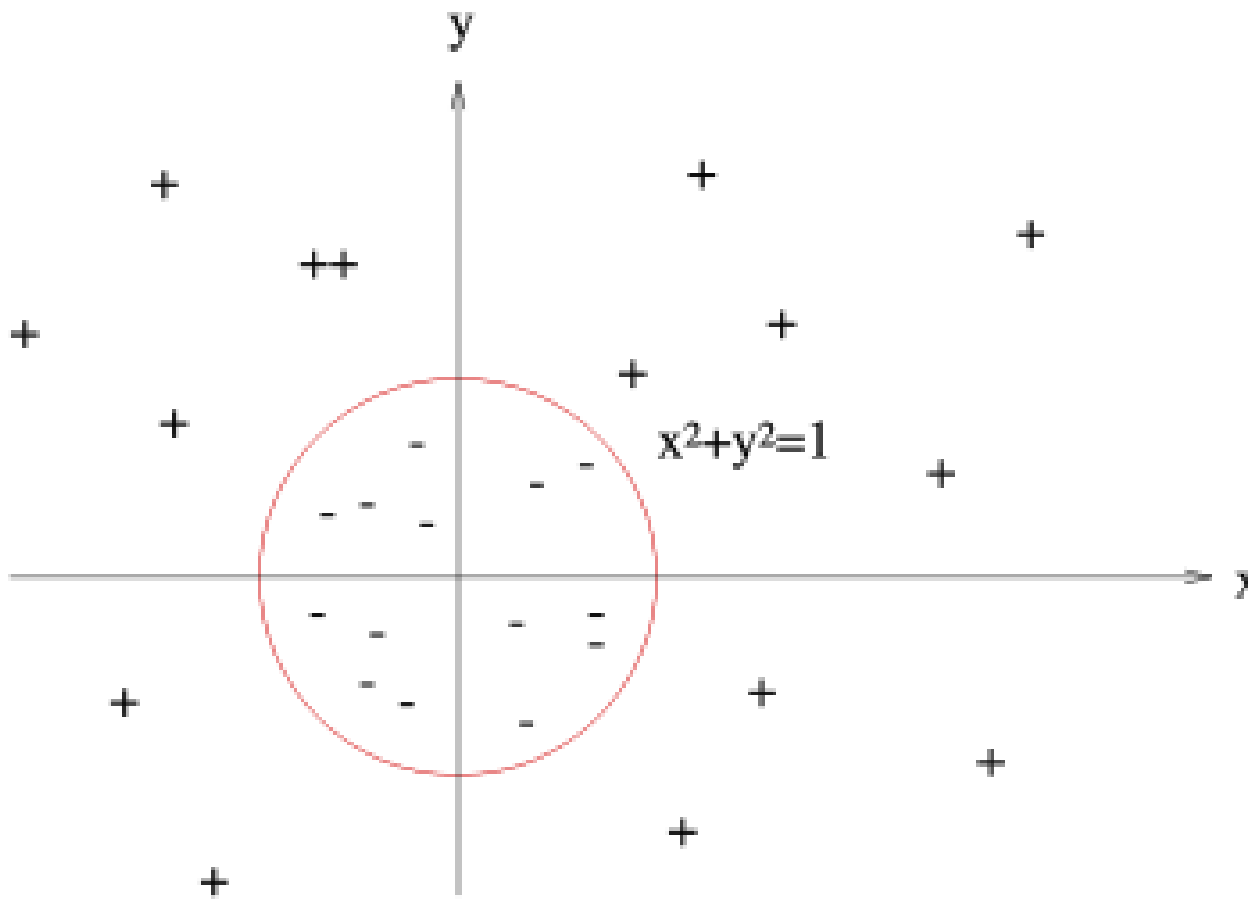

Le modèle du neurone

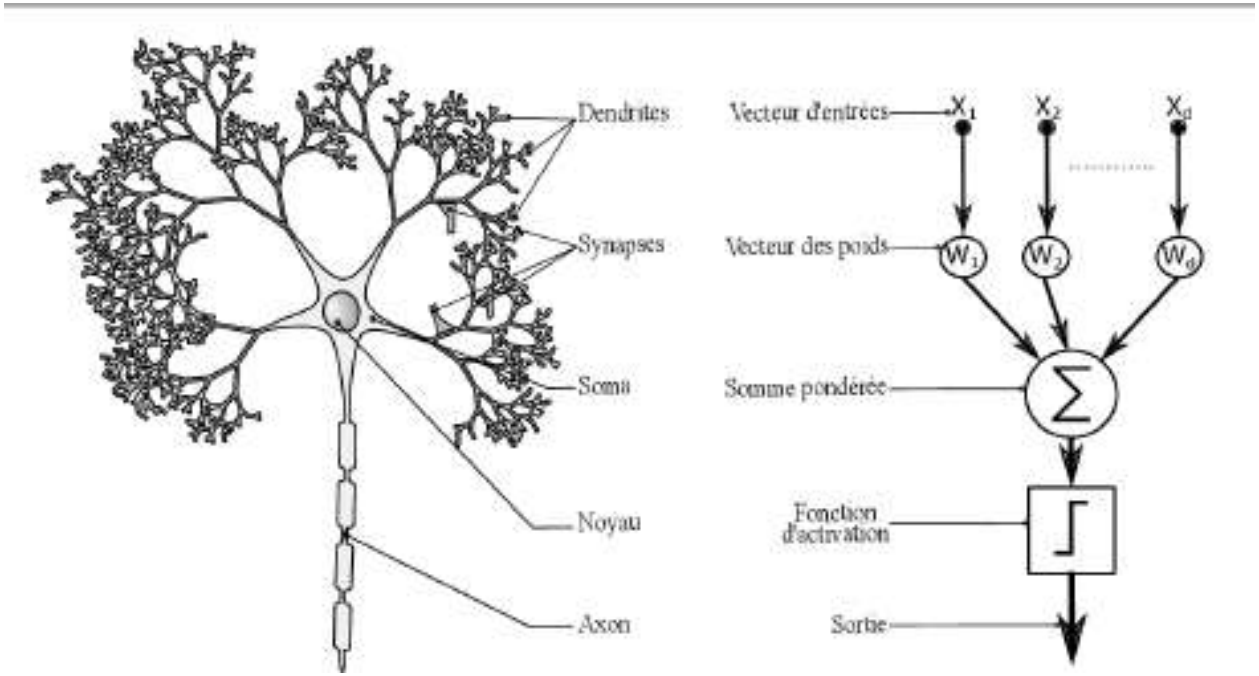

Le modèle du neurone

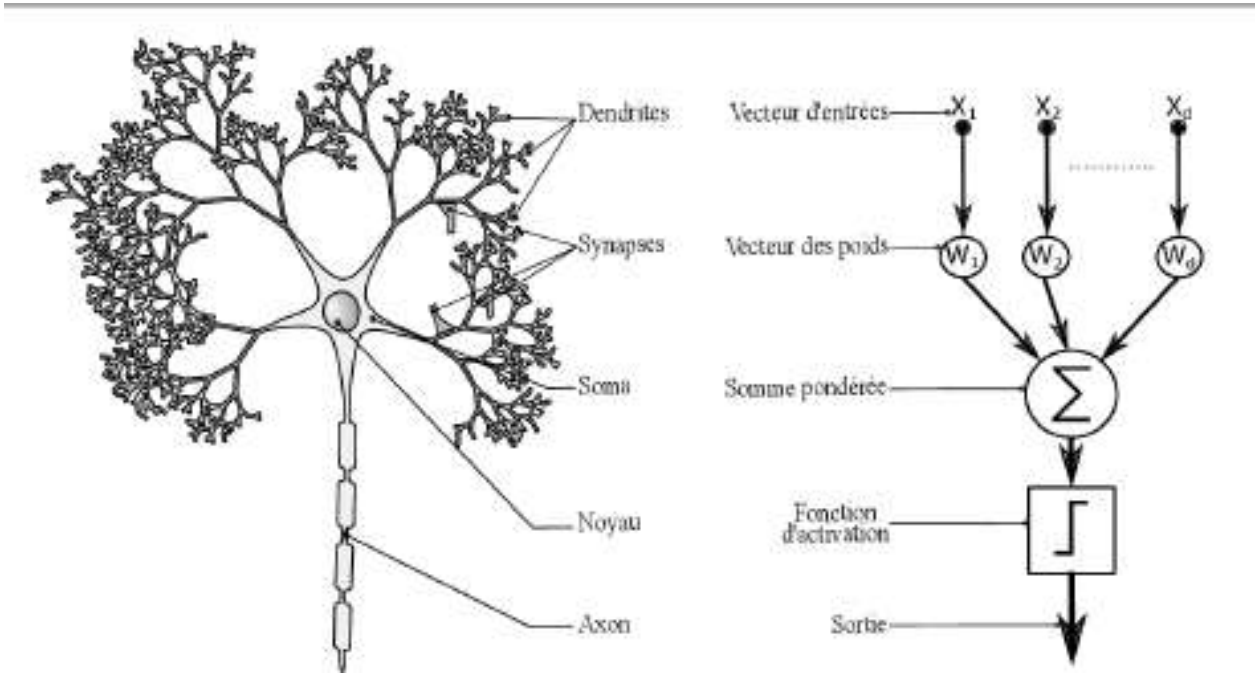

1 neurone c'est comme une frontière hyperplane (ex SVM)

Du neurone au réseau

Le neurone

Dans les architectures de réseaux de neurones (profond ou pas), le neurone est un filtre linéaire :

$$\textit{neurone}_{\alpha,\beta} : \begin{array}{ccc} \mathbb{R}^{\phi} & \rightarrow & \mathbb{R} \\ u & \rightarrow & \alpha.u + \beta \end{array}$$

$\alpha \in \mathbb{R}^{\phi}$ et $\beta \in \mathbb{R}$ sont les **poids** du neurones.

Attention, maintenant, le neurone n'est plus nécessairement connecté à x l'entrée. Il a une entré de taille ϕ indépendante de D.

La couche de neurone

Une couche de ψ de neurones est une séquence de ψ neurones prenant la même entrée, et, dont les ψ sorties sont regroupées en 1 vecteur :

$$\begin{array}{rccc} & \mathbb{R}^{\phi} & \rightarrow & \mathbb{R}^{\psi} \\ couche_{A,b} : & u & \rightarrow & \begin{pmatrix} neurone_{A_1,b_1}(u) \\ \dots \\ neurone_{A_\psi,b_\psi}(u) \end{pmatrix} \end{array}$$

$A \in \mathbb{R}^{\psi \times \phi}$ et $b \in \mathbb{R}^{\psi}$ sont les **poids** de chacun des ψ neurones.

La couche de neurone est aussi linéaire : $couche_{A,b}(u) = Au + b$ mais avec des tailles arbitraires en entrée et sorti.

Du neurone au réseau

Le réseau de neurone

Si on empile 2 couches de neurones c'est exactement comme s'il y en avait qu'une :

$$A'(Au + b) + b' = (A'A)u + (A'b + b')$$

Oui mais si on met une non linéarité entre les 2 c'est différents.

$$A'\mathrm{activation}(Au + b) + b' \neq \mathrm{activation}((A'A)u + (A'b + b'))$$

Le modèle du neurone

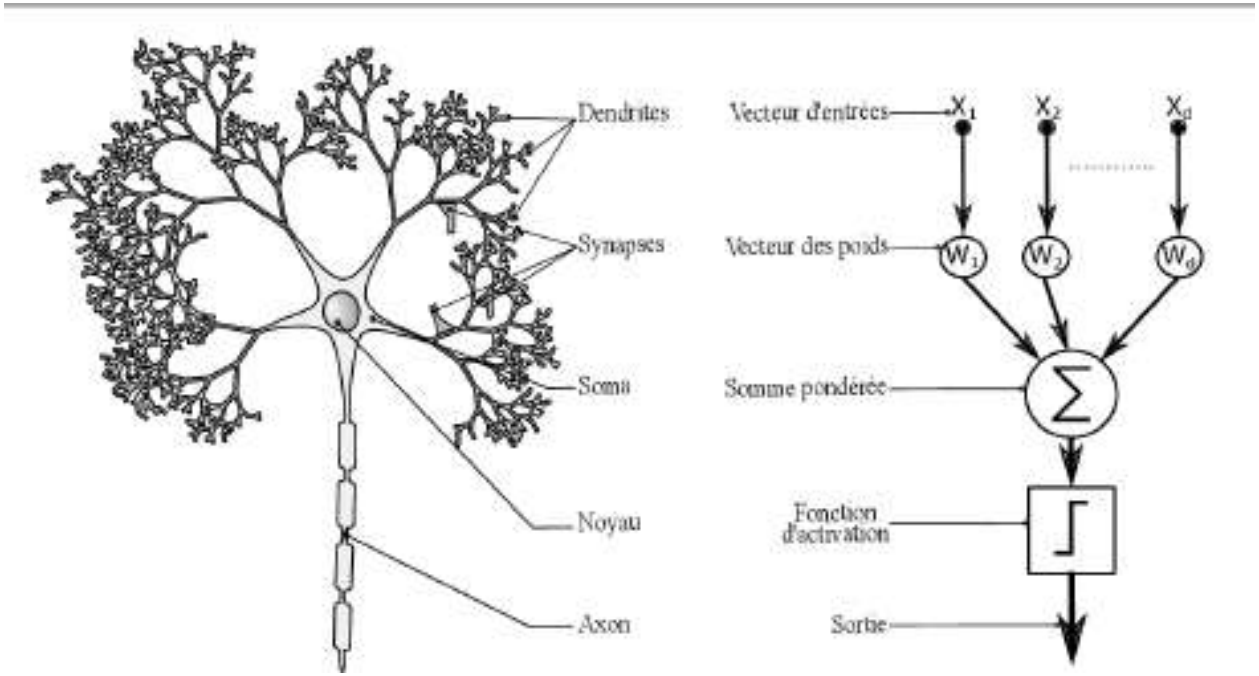

1 neurone c'est comme 1 frontière hyperplane
Mais 2 neurones connecté c'est différent à cause de la fonction d'activation !

Le réseau de neurone

On empile 2 couches de neurones AVEC activation :

$$A' \text{activation}(Au + b) + b'$$

Sur pytorch : il y en a un certain nombre relu, elu, leaky-relu, sigmoide, arctan, hard sigmoid, hard arctan, prelu, relu6, rrelu, celu, selu, gelu, hard shirk, soft shirk, log sigmoid, soft sign, tanh, tanhshirk

globalement avant on utilisait une sigmoide car le gradient existe partout. De 2012 à aujourd'hui, c'est plutôt relu
$relu(u) = [u]_+ = max(u, 0)$ car ça laisse passer le gradient tout en étant simple. Des architectures robustes commencent à utiliser MinMax (voir partie 3).

Du neurone au réseau

Le réseau de neurone

Un réseau de neurones entièrement connectées **MLP** (multi layer perceptron en anglais) de profondeur Q est un empilement de Q couche de neurones - séparé par des activations - la dernière est classiquement un seul neurone :

$$reseau_w : \begin{array}{ccc} \mathbb{R}^D & \rightarrow & \mathbb{R} \\ x & \rightarrow & C_{w_Q}(relu(C_{w_{Q-1}}(...relu(C_{w_1}(x))...))) \end{array}$$

c'est à dire

$$reseau_w(x) = w_Q \times relu(w_{Q-1} \times relu(...(relu(w_1 \times x))))$$

$w_1, ..., w_Q$, Q matrices dont la seule chose imposée étant que w_1 ait D colonnes, et w_Q 1 ligne (et que les tailles soit cohérentes entre elles)

Bilan

SVM vs DL

Dans le cas du SVM, on a $f(x, w) = w^T x + w_{biais}$ qui donne un signe

$$f(x, w) > 0 \text{ ou } f(x, w) < 0$$

pour dire de quel coté on est.
Dans un réseau de neurone c'est PAREIL sauf que

$$f(x, w) = w_Q \times relu(w_{Q-1} \times relu(...(relu(w_1 \times x))))$$

Universalité des réseaux Relu

Valeur absolue D=1

$|x| = relu(x) + relu(-x)$

Universalité des réseaux Relu

Valeur absolue D=2

$||x||_1 = |x_1| + |x_2| = relu(x_1) + relu(-x_1) + relu(x_2) + relu(-x_2)$
marche en fait quelque soit la dimension D (besoin de $2 \times D + 1$ neurones).

Universalité des réseaux Relu

Valeur absolue D=2 avec biais

$||x - q||_1 = |x_1 - q_1| + |x_2 - q_2| =$
$relu(x_1 - q_1) + relu(-x_1 + q_1) + relu(x_2 - q_2) + relu(-x_2 + q_2)$

Le pseudo-dirac

$g_q(x) = relu(1 - ||x - q||_1)$ verifie

$$g_q : \begin{cases} g_q(q) = 1 \\ \forall x \ / \ ||x - q||_1 > 1, \ g_q(x) = 0 \end{cases}$$

Universalité des réseaux Relu

$\forall x_1, ..., x_N \in \mathbb{Z}^D$ tous distincts et $\forall (y_1, ..., y_N) \in \{-1, 1\}^N$,
il suffit de $2 \times N \times D + N + 1$ neurones pour apprendre par coeur la base de données avec $f(x, w)$

$$= \sum_n y_n \times \left(relu \left(1 - \sum_d \left(relu(x_d - x_{n,d}) + relu(-x_d + x_{n,d}) \right) \right) \right)$$

Apprentissage

- On a des points colorés qu'on veut séparer
- Avec 1 neurone
  - Ça revient à cherche un hyperplan séparateur
  - $f_w(x) = w^T x + w_{biais}$
  - Mais il peut ne pas exister de séparation
- Avec un réseau de neurones
  - $f_w(x) = w_Q \times relu(w_{Q-1} \times relu(...(relu(w_1 \times x))))$
  - Avec $O(ND)$ neurones et 3 couches, on peut tout apprendre !

MAIS

- On a des points colorés qu'on veut séparer
- Avec 1 neurone
  - Ça revient à cherche un hyperplan séparateur
  - $f_w(x) = w^T x + w_{biais}$
  - Mais il peut ne pas exister de séparation
- Avec un réseau de neurones
  - $f_w(x) = w_Q \times relu(w_{Q-1} \times relu(...(relu(w_1 \times x))))$
  - Avec $O(ND)$ neurones et 3 couches, on peut tout apprendre !

Attention : tout apprendre ce n'est pas nécessairement bien !

SVM

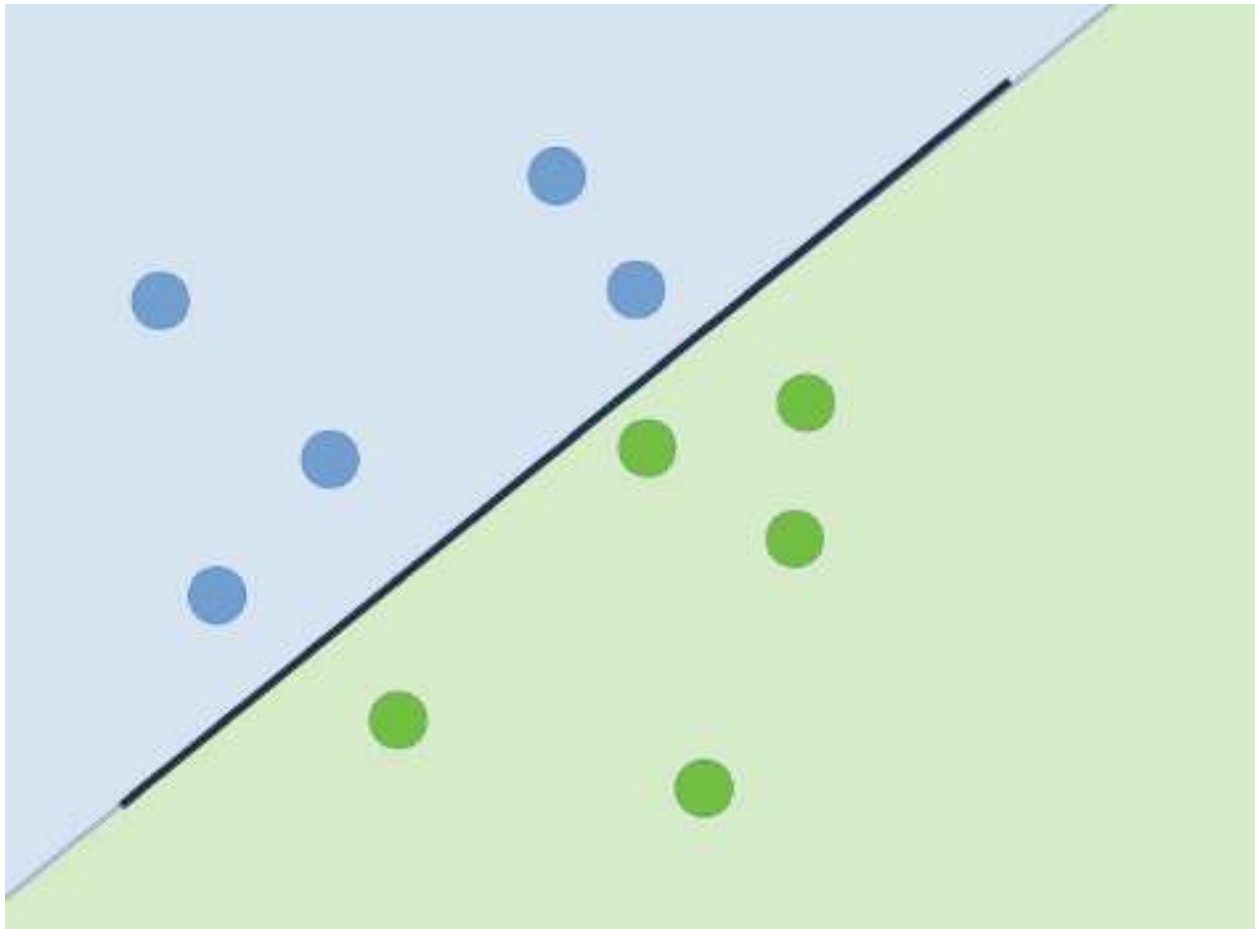

Théorème d'universalité

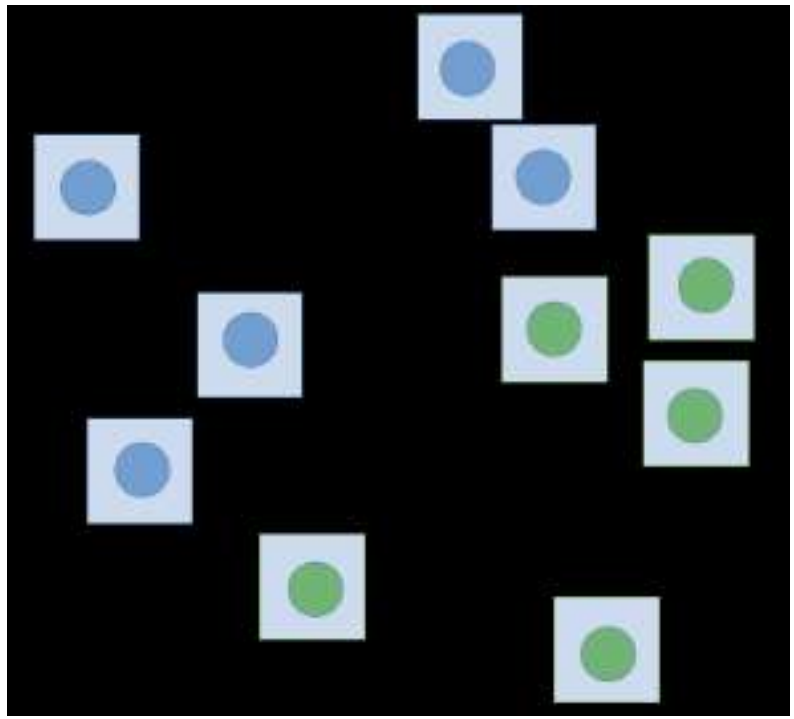

On ne prend aucune décision en dehors de la base d'apprentissage.
Le classifier est **inutile** : il n'a fait qu'encoder la base d'apprentissage, et, ne donne aucune information sur des points hors de cette base.

2 phases

Apprentissage

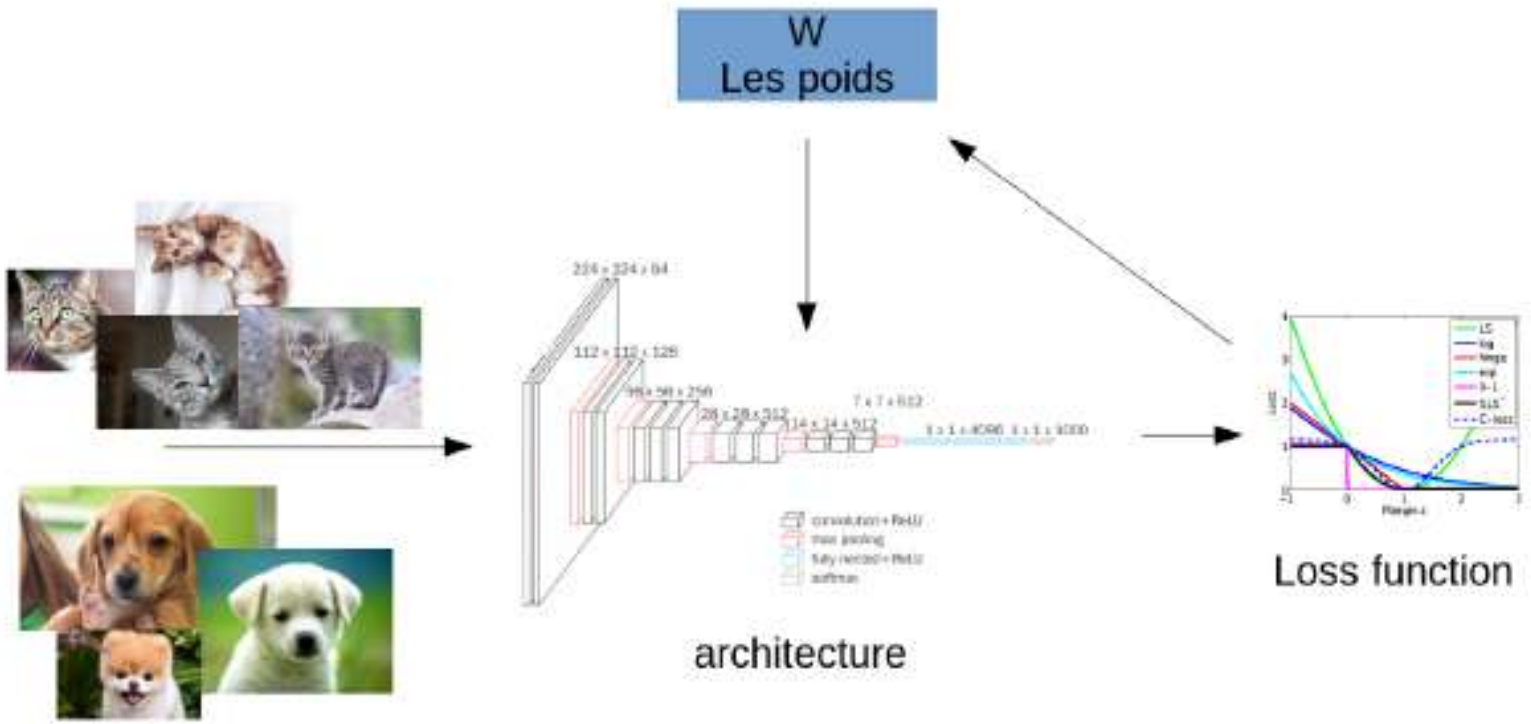

2 phases

Test et/ou production et/ou inférence

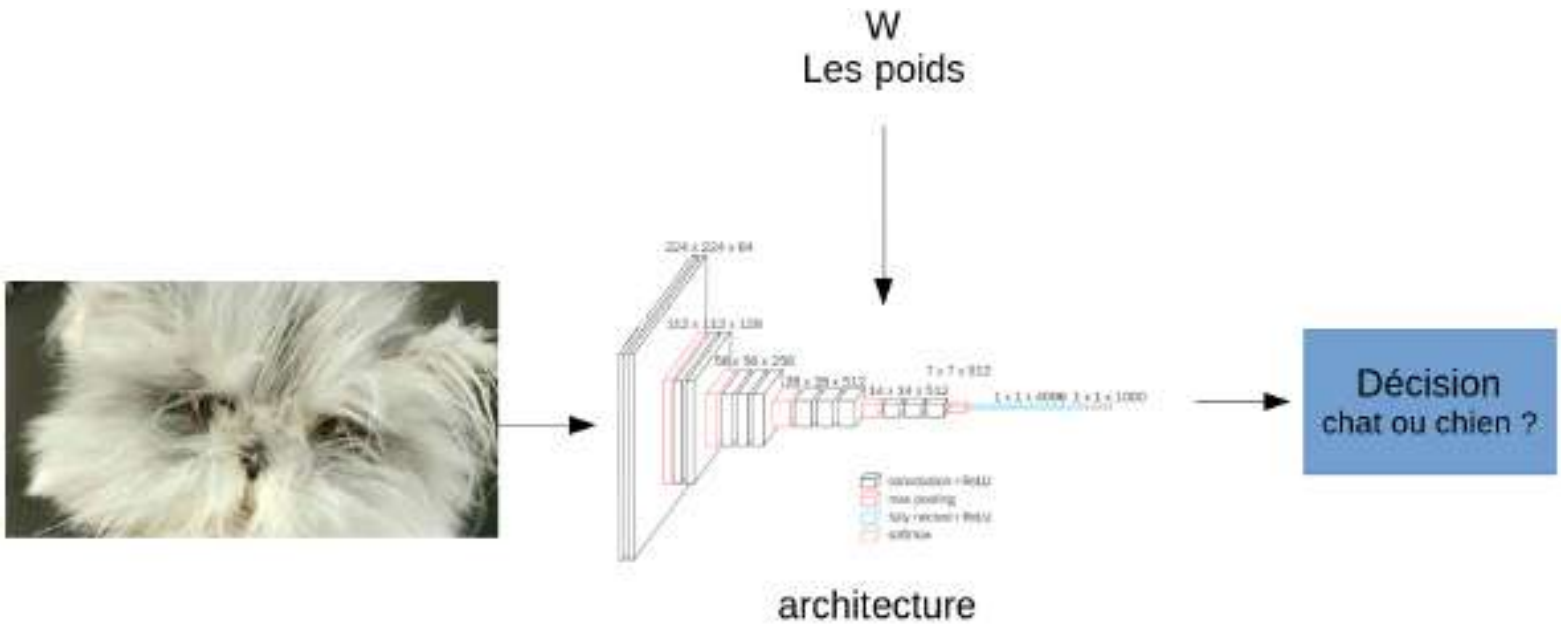

Ce qui compte c'est la performance sur les données de test !

Plan

- Classification de points
  - Apprentissage et test
  - Neurone et réseau
  - Universalité et erreur de généralisation
- Double descente
  - Compromis simplicité/complexité
  - Méthodes par ensemble, double descente
  - Descente de gradient Stochastique
- Traitement de données structurées
  - Neurones convolutif
  - Détection, segmentation, génération...
  - Problème de stabilité

L'ancien paradigme

Vapnik Cherickov

- Pour avoir une *bonne* performance en test, il faut
- ni trop peu de *paramètres*

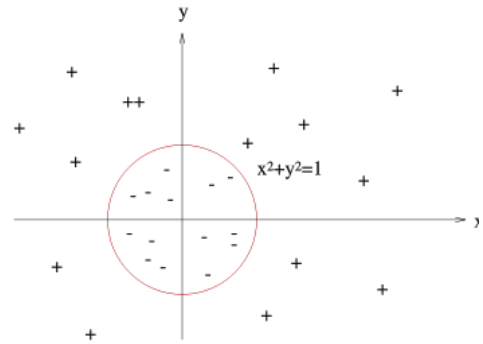

sinon on ne peut pas apprendre

- ni trop de *paramètres*

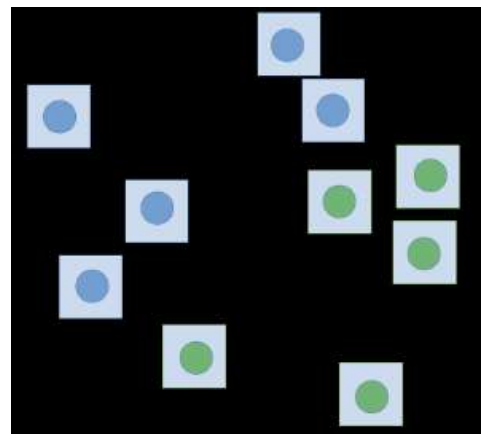

sinon on apprend par coeur

L'ancien paradigme

Vapnik Cherickov

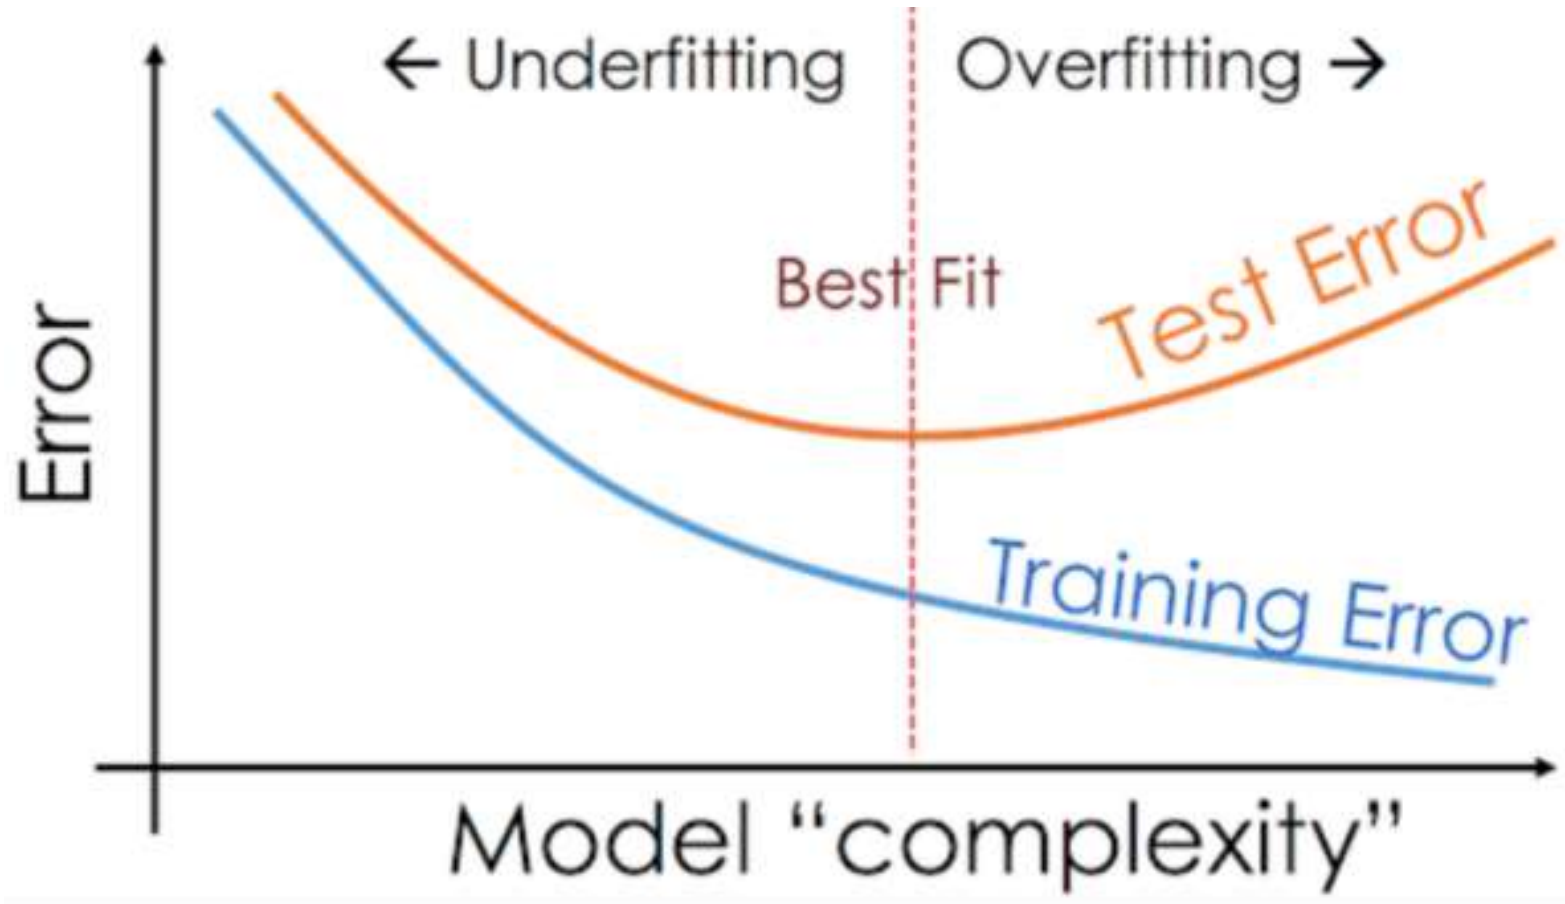

Le NOUVEAU paradigme

Double descente

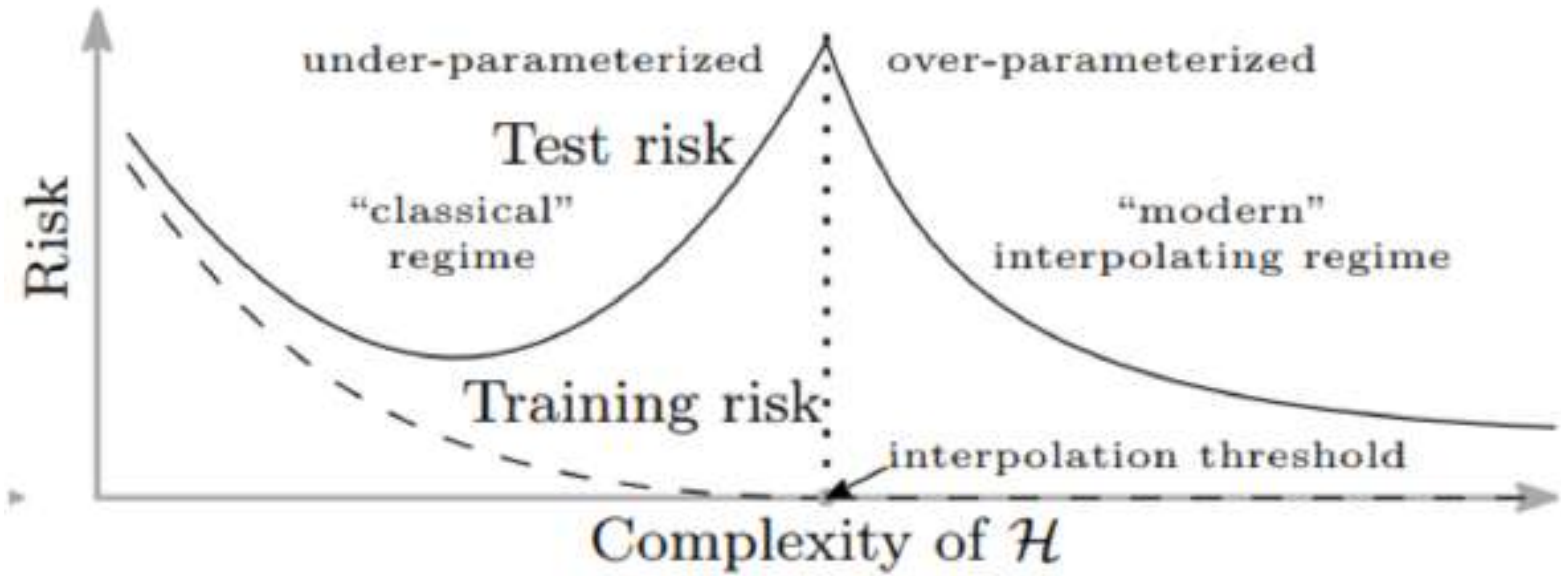

https ://www.lesswrong.com/posts/FRv7ryoqtvSuqBxuT/understanding-deep-double-descent

Le NOUVEAU paradigme

Double descente

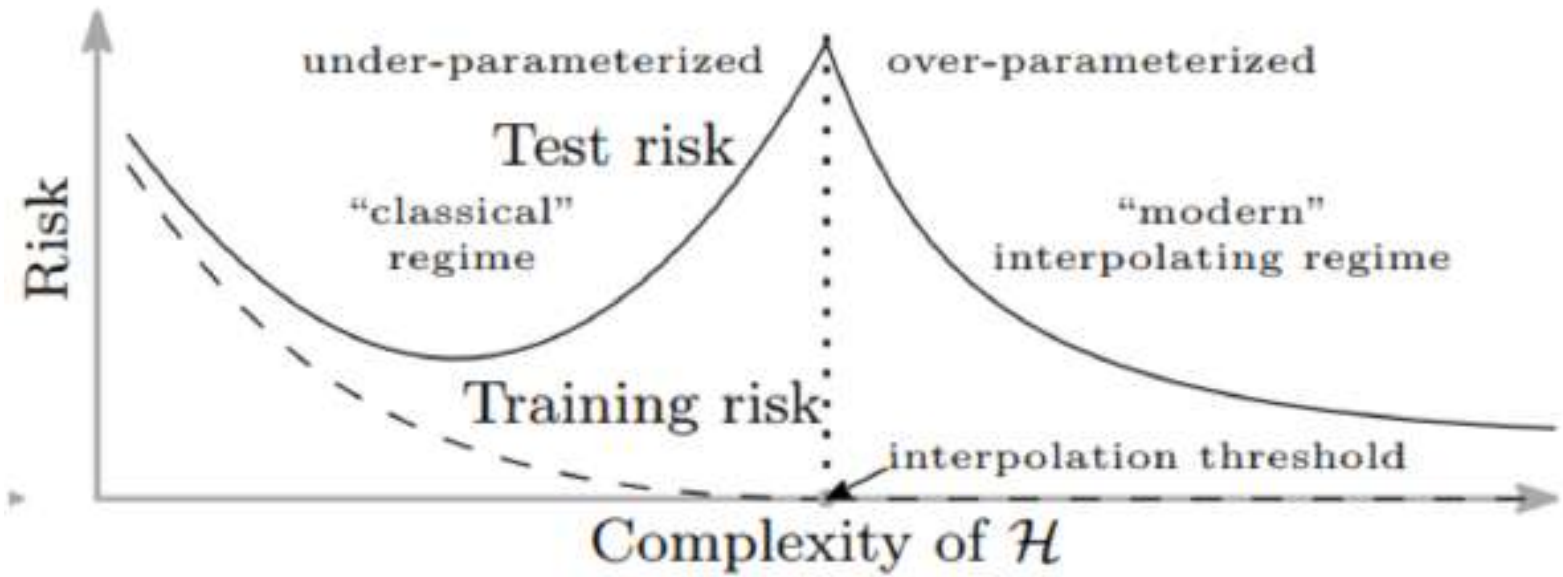

Toujours prendre le plus gros réseaux possible c'est mieux !

Une prime à la puissance plutôt qu'à l'intelligence :-(

Le NOUVEAU paradigme

Pourquoi une double descente ?

Quand on apprend un réseau, on apprendrait en réalité un ensemble de sous réseau dont la complexité s'adapterait au problèmes ? ! ?

2 phases

Apprentissage

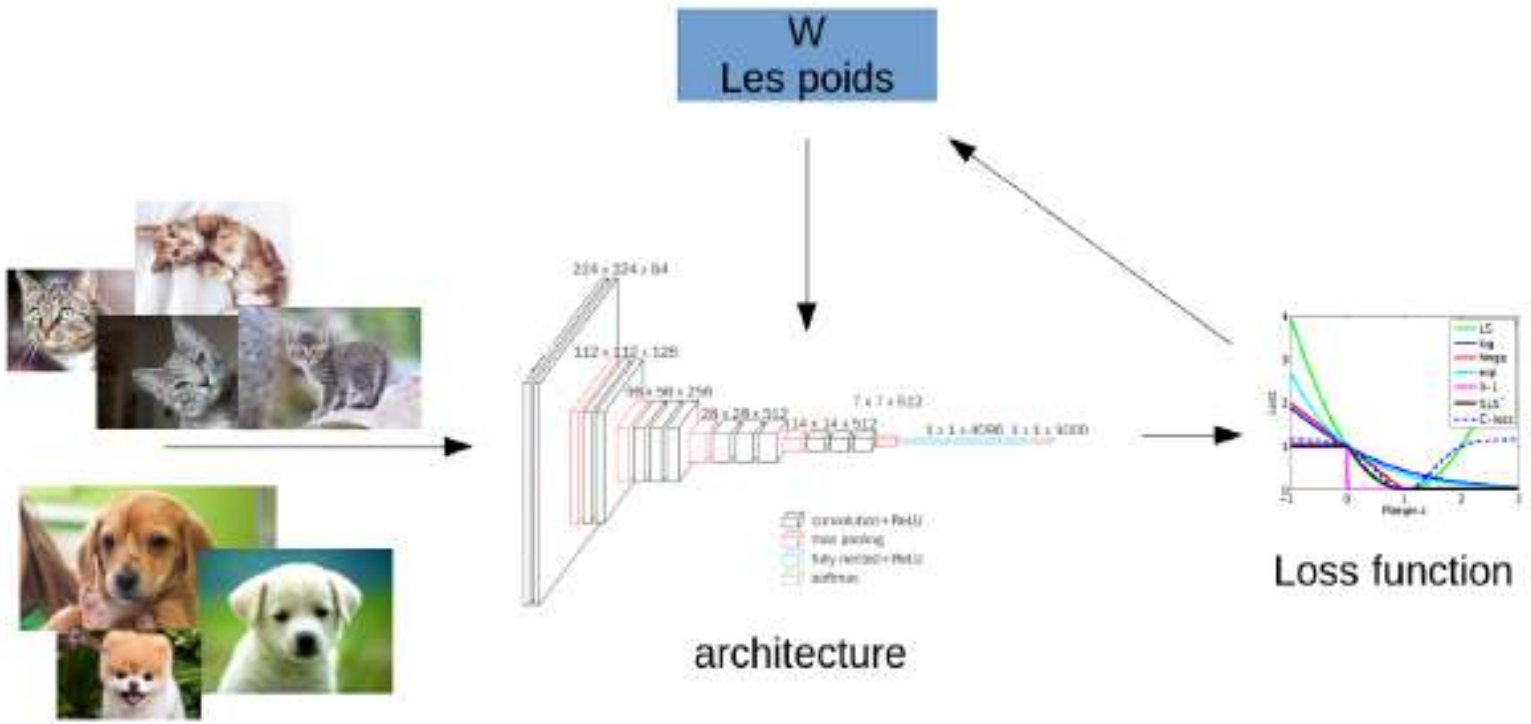

2 phases

Test et/ou production et/ou inférence

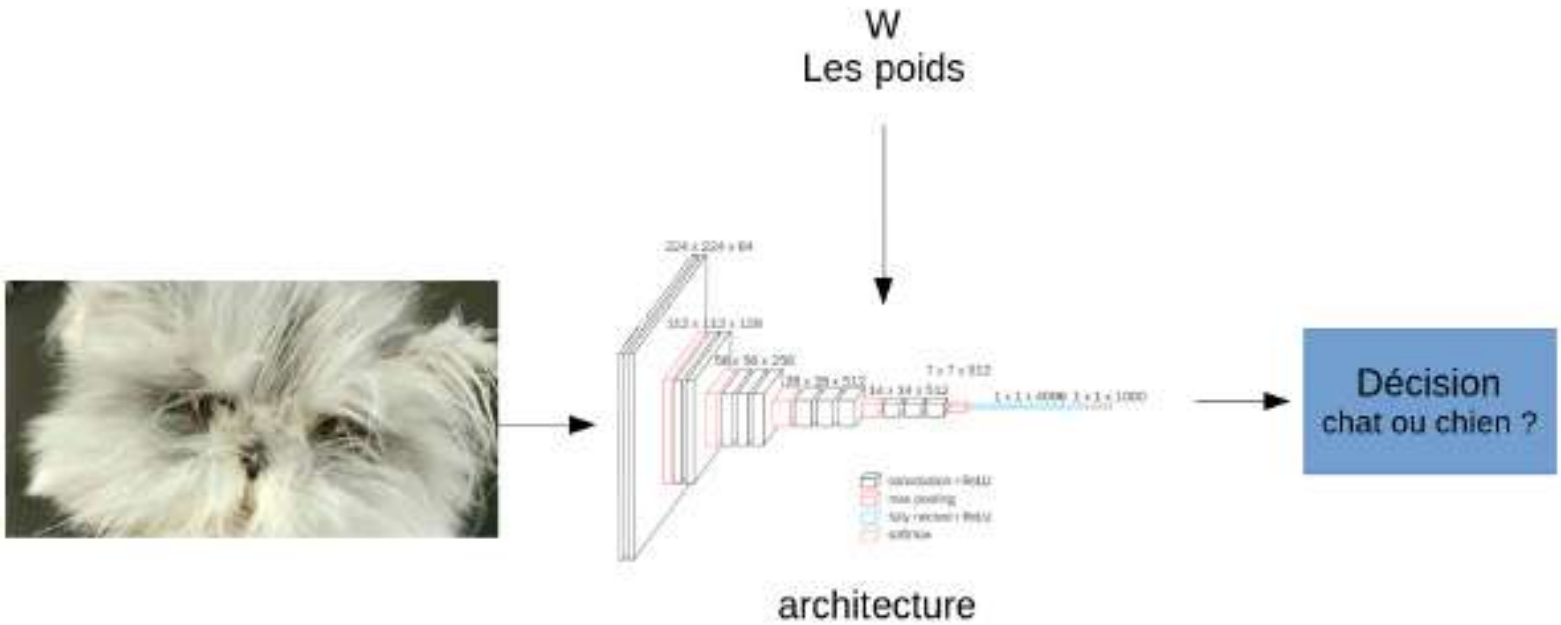

Méthodes ensemblistes

- durant l'apprentissage
  - j'ai $x_1, ..., x_N$, $y_1, ..., y_N$
  - je forme w
- en test, j'utilise w

Méthodes ensemblistes

- si j'apprends plusieurs fois
  - j'ai $x_1, ..., x_N$, $y_1, ..., y_N$
  - je forme w_1, ...,w_K
- en test, je peux fusionner les différents modèles
- je tends alors vers les performances d'un modèle moyen w^*

Méthodes ensemblistes

- si j'apprends $K \gg 1$ fois
  - j'ai $x_1, ..., x_N$, $y_1, ..., y_N$
  - je forme w_1, ...,w_K
- en test, je peux fusionner les différents modèles
- je tends alors vers les performances d'un modèle moyen w^*
- **Attention** w^* n'est pas optimal, il est juste moyen (typiquement pour le SVM dont l'apprentissage est déterministe $w_1 = ... = w_K = w^*$)

Méthodes ensemblistes

La complexité n'augmente **pas** avec le nombre de modèle mais **seulement** avec leur capacité.

Créer plein de modèle équivalent n'augmente pas l'overfitting !

La spécificité des réseaux de neurones ?

ancien paradigme

- K réseaux de Q neurones ce n'est pas comme 1 réseau de KQ neurones
- K ne crée pas d'overfitting
- Q trop petit on n'apprend pas, Q trop grand on overfit

nouveau paradigme

- Un réseau de H neurones va se décomposer nativement en K réseau de $\frac{H}{K}$ neurones
- $\frac{H}{K}$ serait nativement adapté au problème !

Ça n'engage que moi

Personnellement j'ai déjà fait overfitté des réseaux sur des problèmes jouets...
Mais il est vrai que sur une gammes très très grande de taille de réseau, on n'observe pas d'overfitting

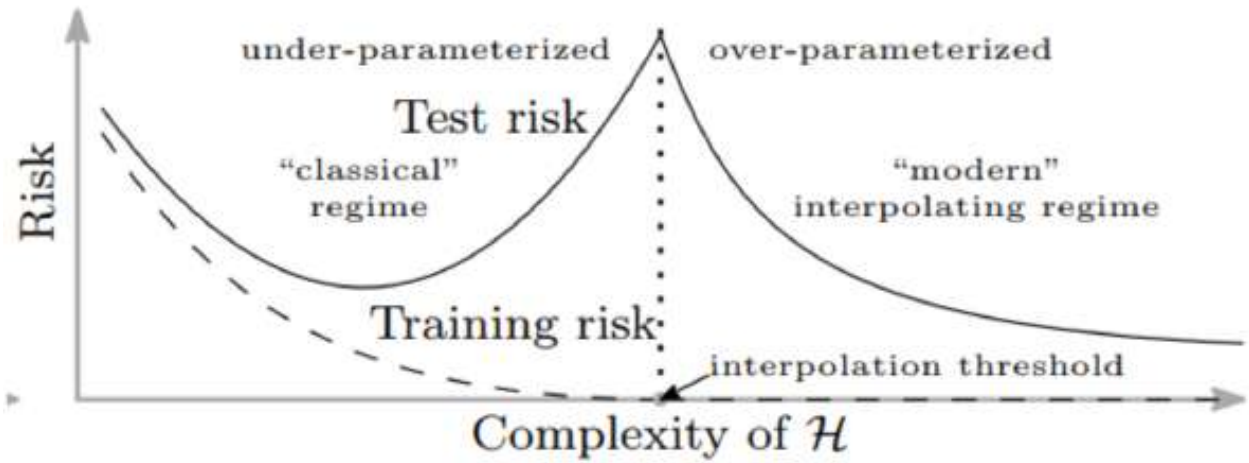

D'où viendrait cette spécificité ?

de la façon de les apprendre :
de la descente de gradient stochastique

La descente de gradient

F est une fonction dérivable de $\mathbb{R}^D$ dans $\mathbb{R}$ alors
$\forall u, h \in \mathbb{R}^D$, $F(u+h) = F(u) + \nabla F_u | h + o(h)$
avec $ho(h) \underset{h \to 0}{\to} 0$ (notation petit o classique)
Donc si $\nabla F_u \neq 0$ alors il existe $\lambda > 0$ tel que $F\left(u - \lambda \nabla F_u\right) < F(u)$

La descente de gradient

pseudo code

input : F, u_0

1. $u = u_0$
2. calculer ∇F_u
3. si $\nabla F_u \approx 0$ ou early stopping alors sortir
4. $\lambda = 1$
5. tant que $F\left(u - \lambda \nabla F_u\right) \geq F(u)$ faire $\lambda = 0.5\lambda$
6. $u = u - \lambda \nabla F_u$
7. go to 2

La descente de gradient

pseudo code

input : F, u_0

1. $u = u_0$
2. calculer ∇F_u
3. si $\nabla F_u \approx 0$ ou early stopping alors sortir
4. $\lambda = 1$
5. tant que $F\left(u - \lambda \nabla F_u\right) \geq F(u)$ faire $\lambda = 0.5\lambda$
6. $u = u - \lambda \nabla F_u$
7. go to 2

cet algorithme converge vers un point u^* tel que $\nabla F_u = 0$

Apprentissage et descente de gradient

Appliquer à l'apprentissage :

- la variable u de la descente de gradient est les poids w du réseau
- la fonctionnelle (F) est (+/-) l'erreur d'apprentissage :
  $F(w) \approx \sum_n \mathbf{1}_-(y(x_n)f(x_n, w))$
  avec $\mathbf{1}_-(t) = 1$ si $t \leq 0$ et $\mathbf{1}_-(t) = 0$ si $t > 0$

Apprentissage et descente de gradient

Test :

w fixé, on prend χ, et, on doit calculer $f(\chi, w)$

Apprentissage :

On prend $x_1, ..., x_N$, et, on doit **approximer**

$$\min_w \sum_n \mathbf{1}_-(y(x_n) f(x_n, w))$$

Fonction de perte

La descente de gradient ne marche qu'avec des fonctions globalement lisse.
Utiliser $F(w) = \min_w \sum_n \mathbf{1}_-(y(x_n)f(x_n, w))$ ne peut pas marcher

Fonction de perte

La descente de gradient ne marche qu'avec des fonctions globalement lisse.
Utiliser $F(w) = \min_w \sum_n \mathbf{1}_-(y(x_n)f(x_n, w))$ ne peut pas marcher
Il faut lisser l'erreur d'apprentissage via une loss function

$$F(w) = loss\,(w) = \sum_n l(y(x_n)f(x_n, w))$$

Fonction de perte

$$F(w) = loss\,(w) = \sum_n l(y(x_n)f(x_n, w))$$

- l doit être assez lisse
- l doit avoir une valeur proche de 0 si $y(x_n)f(x_n, w)$ est grand
- l doit avoir une valeur très supérieure à 0 si $y(x_n)f(x_n, w)$ est très petit

Fonction de perte

$$F(w) = loss\,(w) = \sum_n l(y(x_n)f(x_n, w))$$

- l doit être assez lisse
- l doit avoir une valeur proche de 0 si $y(x_n)f(x_n, w)$ est grand
- l doit avoir une valeur très supérieure à 0 si $y(x_n)f(x_n, w)$ est très petit

hinge loss :

$$loss\,(w) = \sum_n relu(1 - y_n f(x_n, w))$$

Fonction de perte

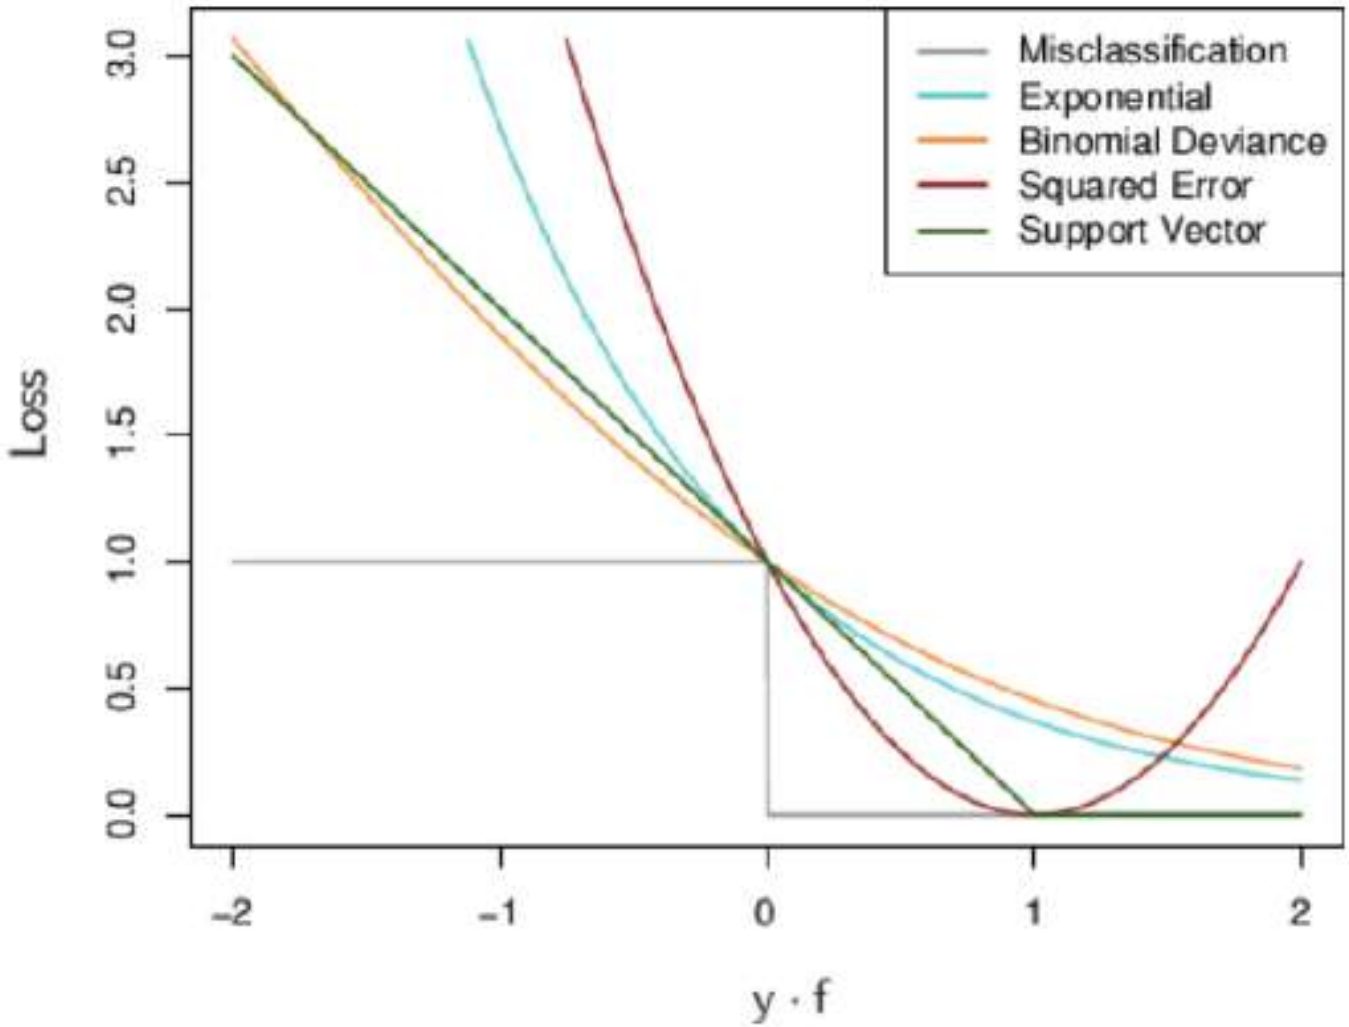

Limite de la descente de gradient

$$loss\,(w) = \sum_n relu(1 - y_n f\,(x_n, w))$$

Si $N = 1000000$ ça veut dire que pour calculer $loss(w)$ je dois appliquer f (plusieurs couches) à 1000000 points !

Descente de gradient stochastique

loss est une fonction dérivable de $\mathbb{R}^D$ dans $\mathbb{R}$
et que $\mathit{loss}(u) = \sum_{i=1} q_i(u)$
alors **dans le cas convexe**, il est possible de minimiser *loss* en faisant comme une descente de gradient mais en prenant une sous sommes des q_i tirée aléatoirement avec une politique $\lambda(t)$ fixée a priori (qui doit quand même vérifier certaines conditions).

Descente de gradient stochastique

pseudo code

input : $x_1, y_1, ..., x_n, y_n,\ w_0$

1. $w = w_0$
2. $iter = 0$
3. tirer n au hasard dans 1,...,N
4. $partial\_loss = relu(1 - y_n f(x_n, w))$
5. calculer $\nabla_w partial\_loss$
6. $w = w - \lambda_{iter} \nabla_w partial\_loss$
7. $iter = iter + 1$
8. si condition d'arrêt alors sortir
9. go to 3

Descente de gradient stochastique

Optimizer

$w = w - \lambda_{iter} \nabla_w partial\_loss$ est une possibilité mais il y en a d'autres :

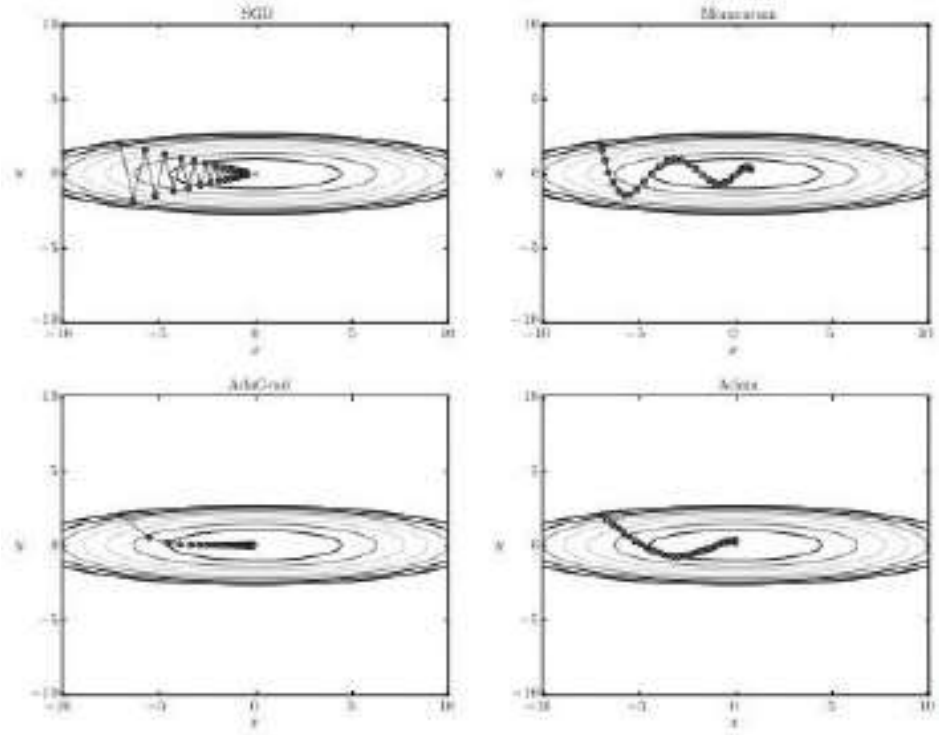

L'apprentissage

$$f(x, w) = w_Q \times relu(w_{Q-1} \times relu(...(relu(w_1 \times x))))$$

L'apprentissage consiste à appliquer la méthode de la descente de gradient stochastique (optimiseur à choisir) à une fonction de perte (à choisir) qui approxime l'erreur d'apprentissage
Par exemple

$$partial\_loss\,(w) = \sum_{n \in Batch} relu(1 - y_n f(x_n, w))$$

$$w = w - \lambda_{iter} \nabla_w partial\_loss$$

Forward - Backward

Mais ça suppose qu'on sache calculer le gradient ! ! ! !

Forward - Backward

objectif

$$partial\_loss(w) = \sum_{n \in Batch} relu(1 - y_n f(x_n, w))$$

avec $f(x, w) = w_Q \times relu(w_{Q-1} \times relu(...(relu(w_1 \times x))))$

$\Rightarrow$ on veut calculer

$$\partial \frac{\partial partial\_loss(w)}{\partial w_{t,i,j}}$$

Forward - Backward

Forward

```
for t
    for i
        for j
            A[t][i] += relu(A[t-1][j])*w[t-1][i][j]
```

Forward - Backward

Réduction w - α

$$\frac{\partial loss}{\partial w_{t,i,j}} = \frac{\partial loss}{\partial \alpha_{t,i,j}} \frac{\partial \alpha_{t,i}}{\partial w_{t,i,j}} = \frac{\partial loss}{\partial \alpha_{t,i}} x_{t,j}$$

Forward - Backward

Réduction α - α

$$\frac{\partial loss}{\partial \alpha_{t,j}} = \sum_i \frac{\partial loss}{\partial \alpha_{t+1,i}} \frac{\partial \alpha_{t+1,i}}{\partial \alpha_{t,j}} = \sum_i \frac{\partial loss}{\partial \alpha_{t+1,i}} w_{t,i,j} relu'(\alpha_{t,j})$$

relu est une fonction linéaire par morçeau, sa *dérivé* est donc une constante par morçeau

Forward - Backward

Attention

La somme dans $\frac{\partial loss}{\partial \alpha_{t,j}} = \sum_i \frac{\partial loss}{\partial \alpha_{t+1,i}} \frac{\partial \alpha_{t+1,i}}{\partial \alpha_{t,j}}$ ne vient **pas** de la somme dans $\alpha_{t+1,i} = \sum_j x_{t,j} w_{t,i,j}$.

Elle vient de $f(u) = a(b(u), c(u))$ implique $\frac{\partial f}{\partial u} = \frac{\partial a}{\partial b}\frac{\partial b}{\partial u} + \frac{\partial a}{\partial c}\frac{\partial c}{\partial u}$.

Lui même vient de $f(u+h) = f(u) + f'(u)h$

Forward - Backward

```
for t
    for i
        for j
            A[t][i] += relu(A[t-1][j])*w[t-1][i][j]
DA[z][1] = partial_loss
for t from z to 1
    for j
        for i
            DA[t][j] += DA[t+1][i]*w[t][i][j]*relu'(A[t][j])
```

ou, en pytorch

```
z = net(x)
loss = criterion(z,y)
loss.backward
```

Message to take home

- Ce qui est embêtant avec le DL c'est que rien n'est *monotone* :
  - sur le nombre de neurones (parfois plus c'est mieux)
  - sur le volume de données (parfois plus c'est moins bien)

  $\Rightarrow$ Tous les réglages sont longs et nécessitent beaucoup de ressource de calcul

Message to take home

- Ce qui est embêtant avec le DL c'est que rien n'est *monotone* :
  - sur le nombre de neurones (parfois plus c'est mieux)
  - sur le volume de données (parfois plus c'est moins bien)

$\Rightarrow$ Tous les réglages sont longs et nécessitent beaucoup de ressource de calcul

$\Rightarrow$ **exemple du learning rate**

$(w = w - lr \times \nabla partial\_Loss)$

Réglage du learning rate

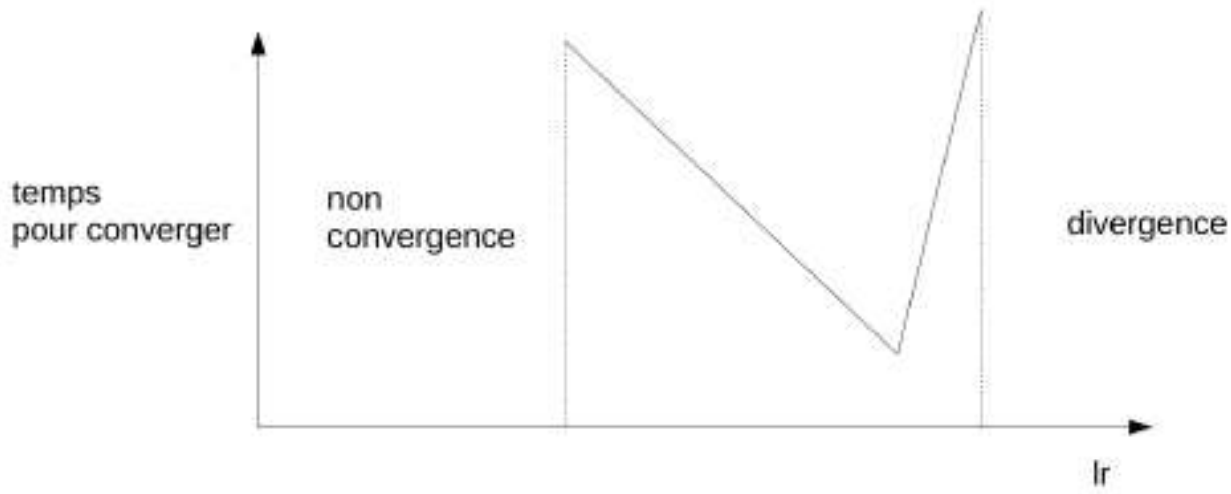

Réglage du learning rate

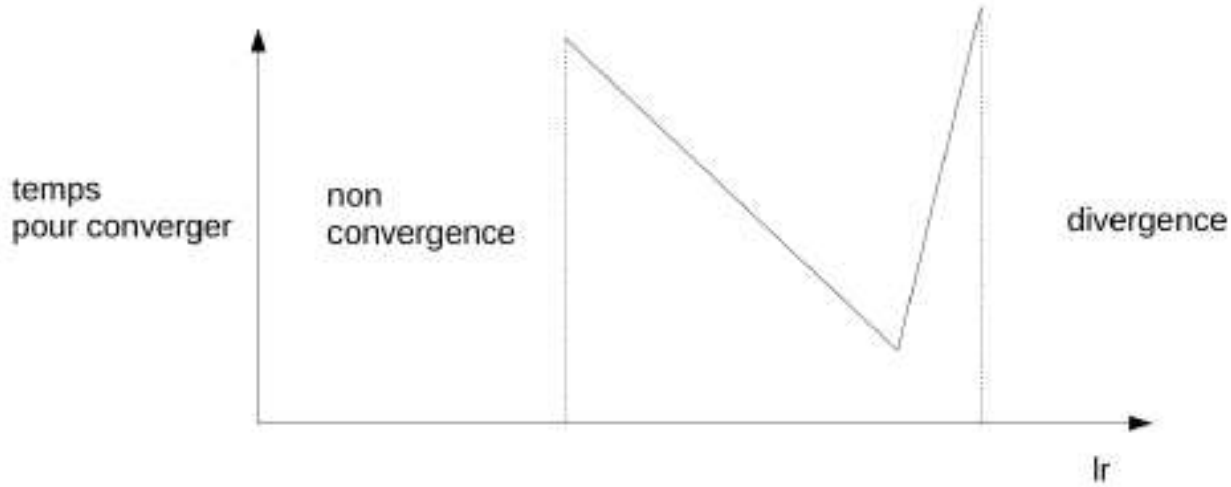

Oui MAIS : la performance en test est meilleure quand la convergence a lieu avec un lr fort !

Towards Explaining the Regularization Effect of Initial Large Learning Rate in Training Neural Networks

Réglage du learning rate

Un learning rate plus faible permet de prendre des raccourcis qui accélère l'apprentissage mais pousse à apprendre du bruit !

(Un learning rate plus faible augmenterait la capacité du réseau !)

Réglage du learning rate

Vous pouvez obtenir 2% d'erreurs en apprentissage en 5mins sur CIFAR10.
Pourtant les meilleurs codes CIFAR10 tournent pendant des nuits pour gagner quelques % en test !

Encore une fois une grosse prime à la puissance plus qu'à l'intelligence :-(

Plan

- Classification de points
  - Apprentissage et test
  - Neurone et réseau
  - Universalité et erreur de généralisation
- Double descente
  - Compromis simplicité/complexité
  - Méthodes par ensemble, double descente
  - Descente de gradient Stochastique
- Traitement de données structurées
  - Neurones convolutif
  - Segmentation
  - Problème de stabilité

Données structurées

Avant le deep learning

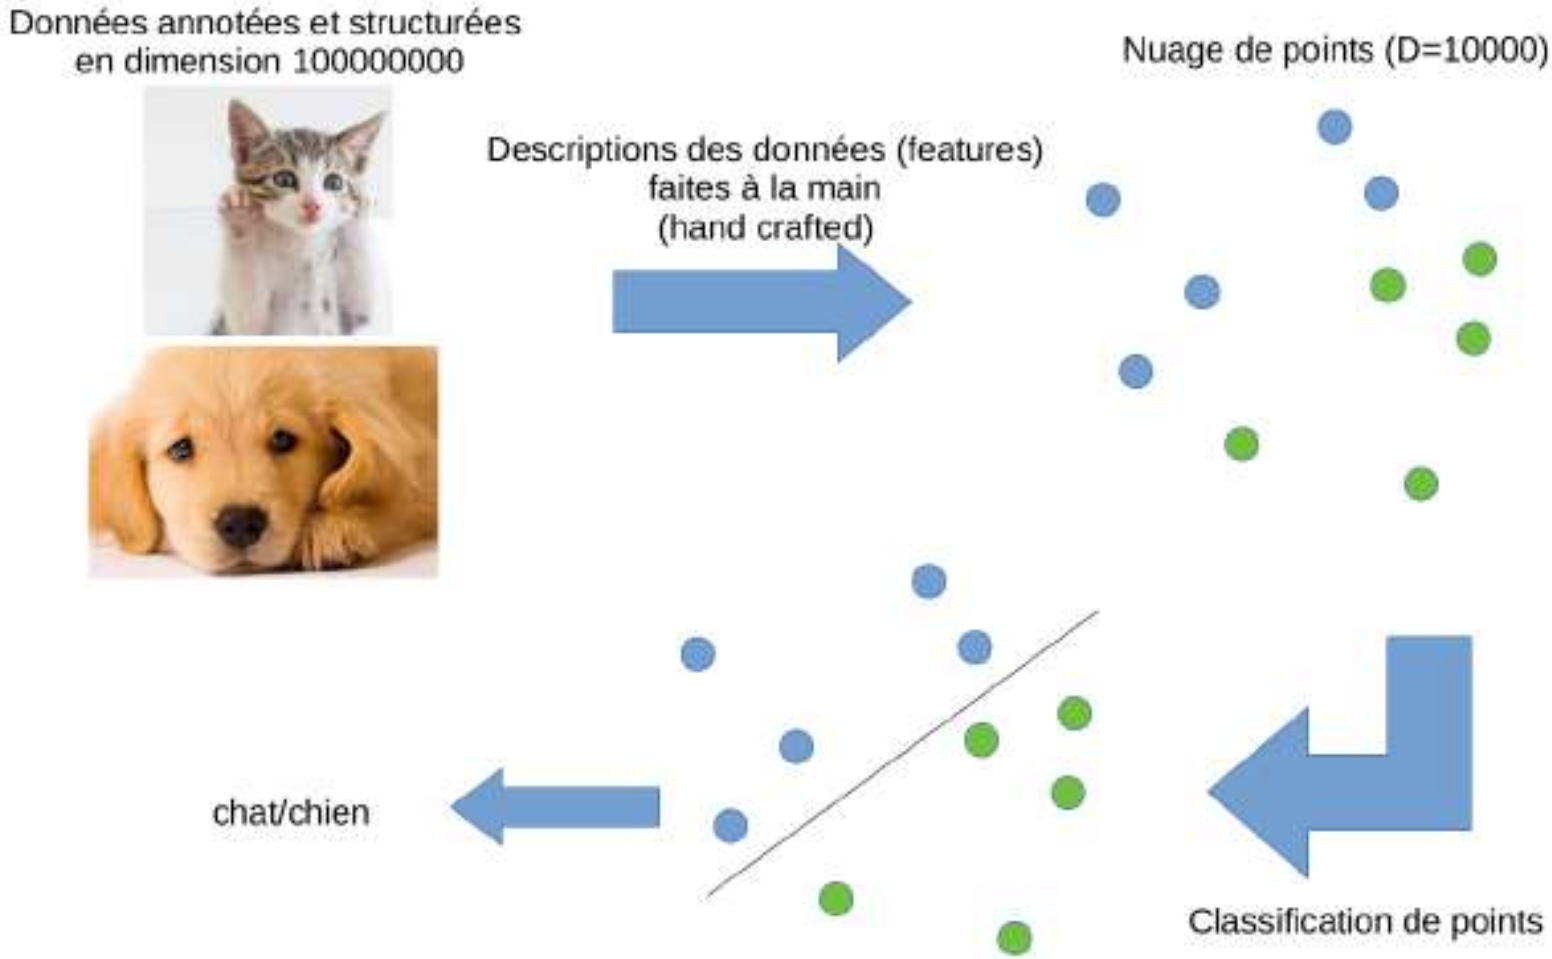

Données structurées

Après

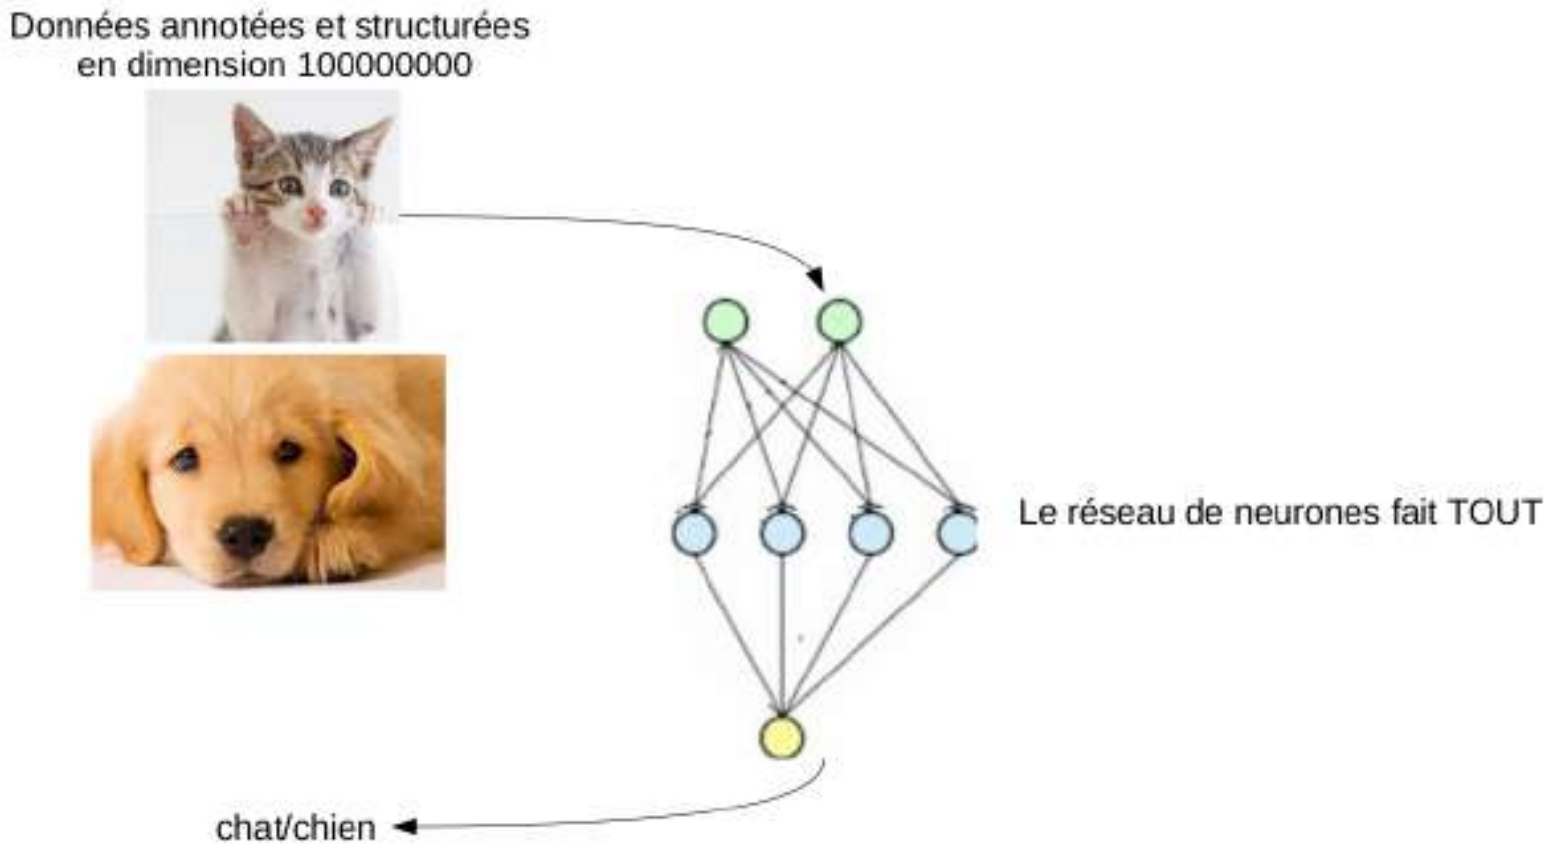

Données structurées

Le neurone convolutif

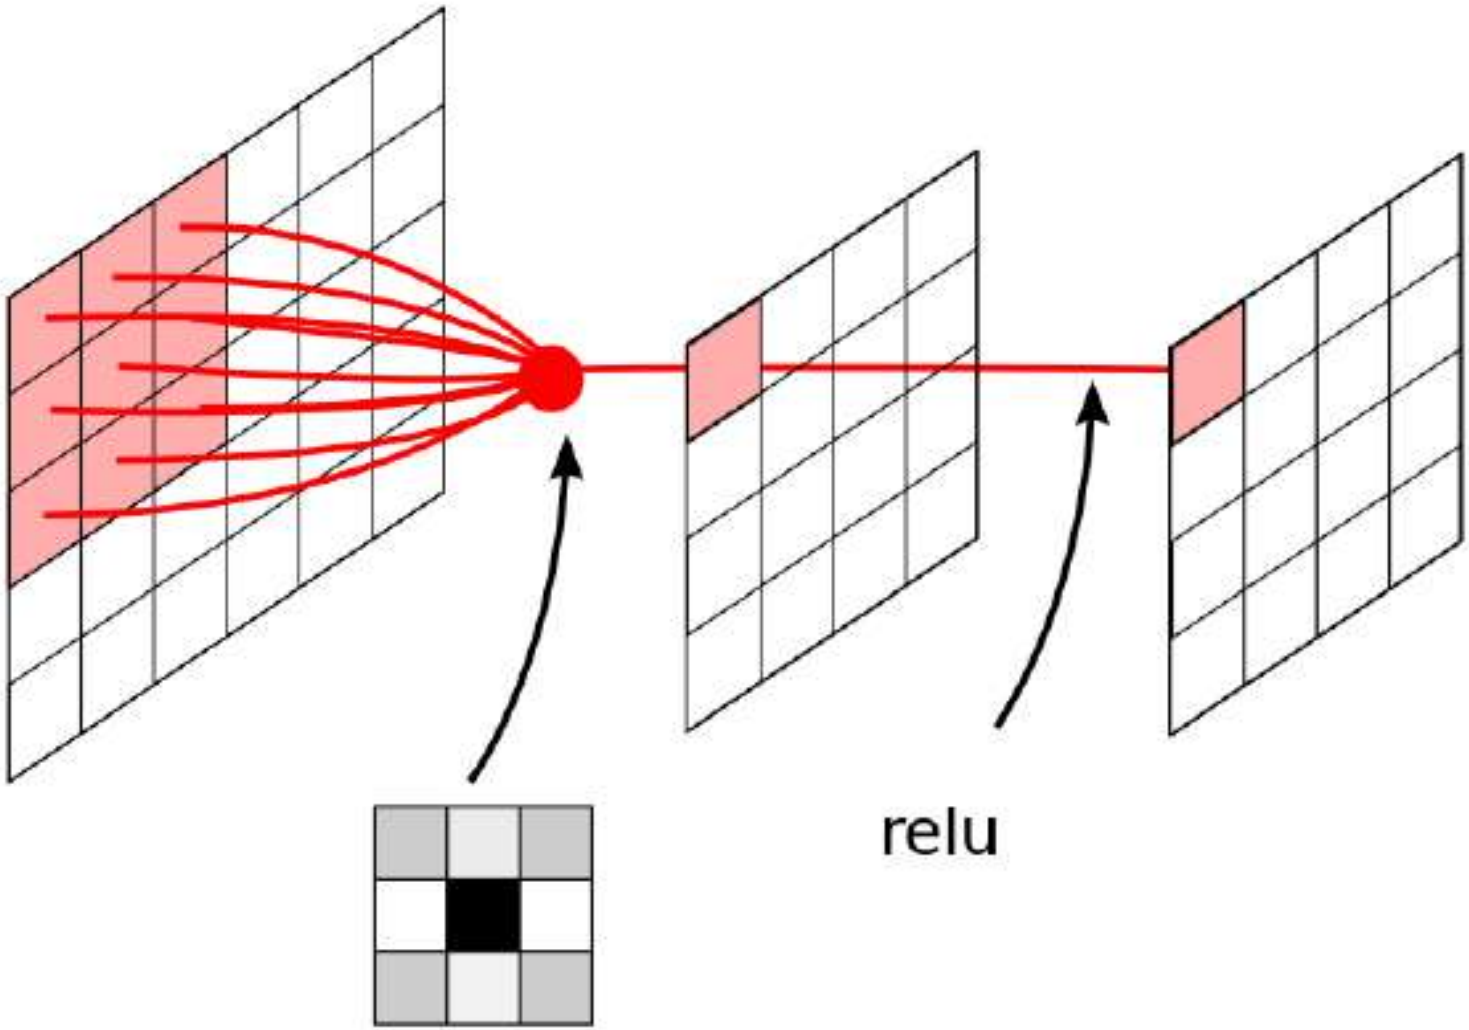

Données structurées

Le pooling

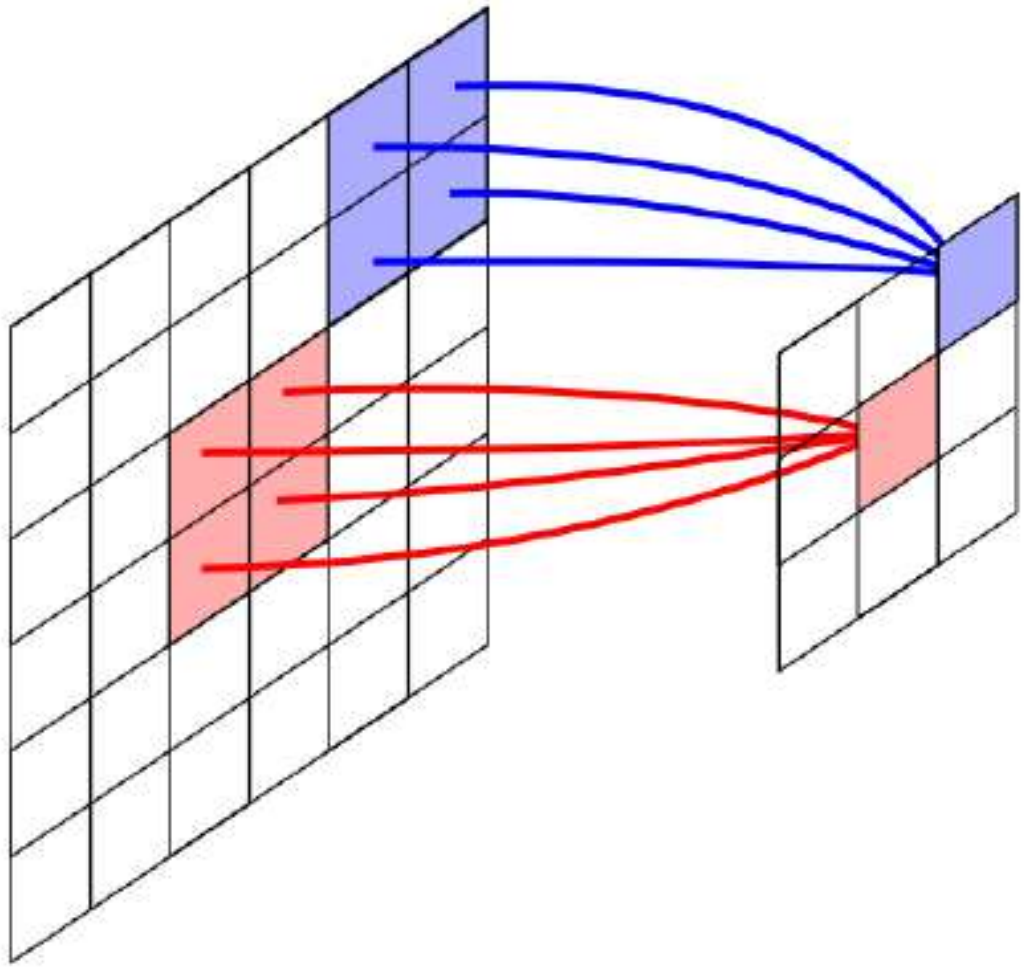

Données structurées

Lenet

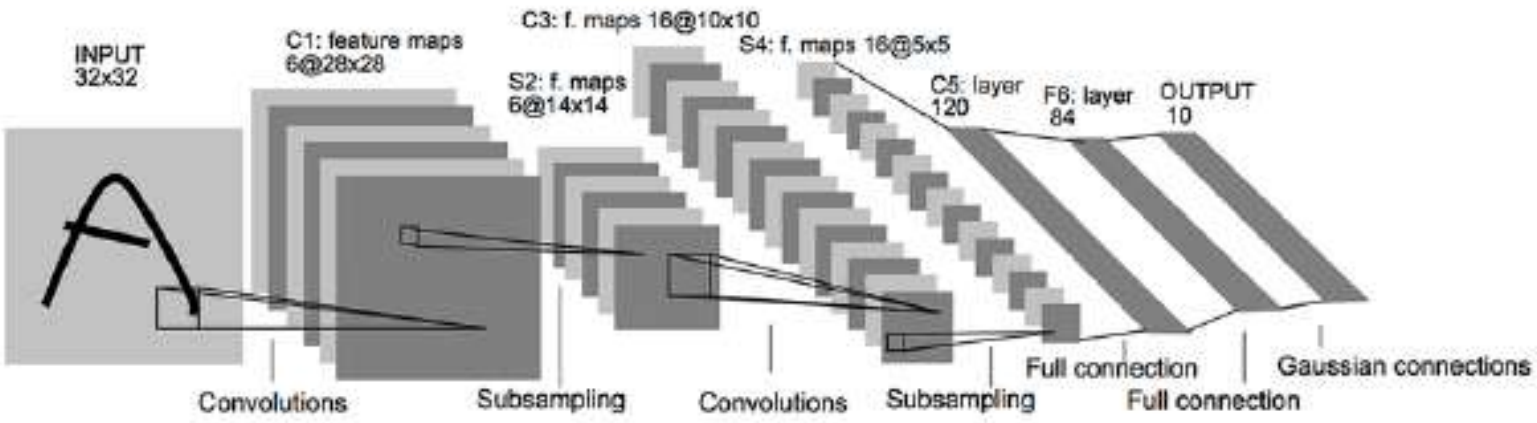

Données structurées

Lenet, Alexnet, VGG

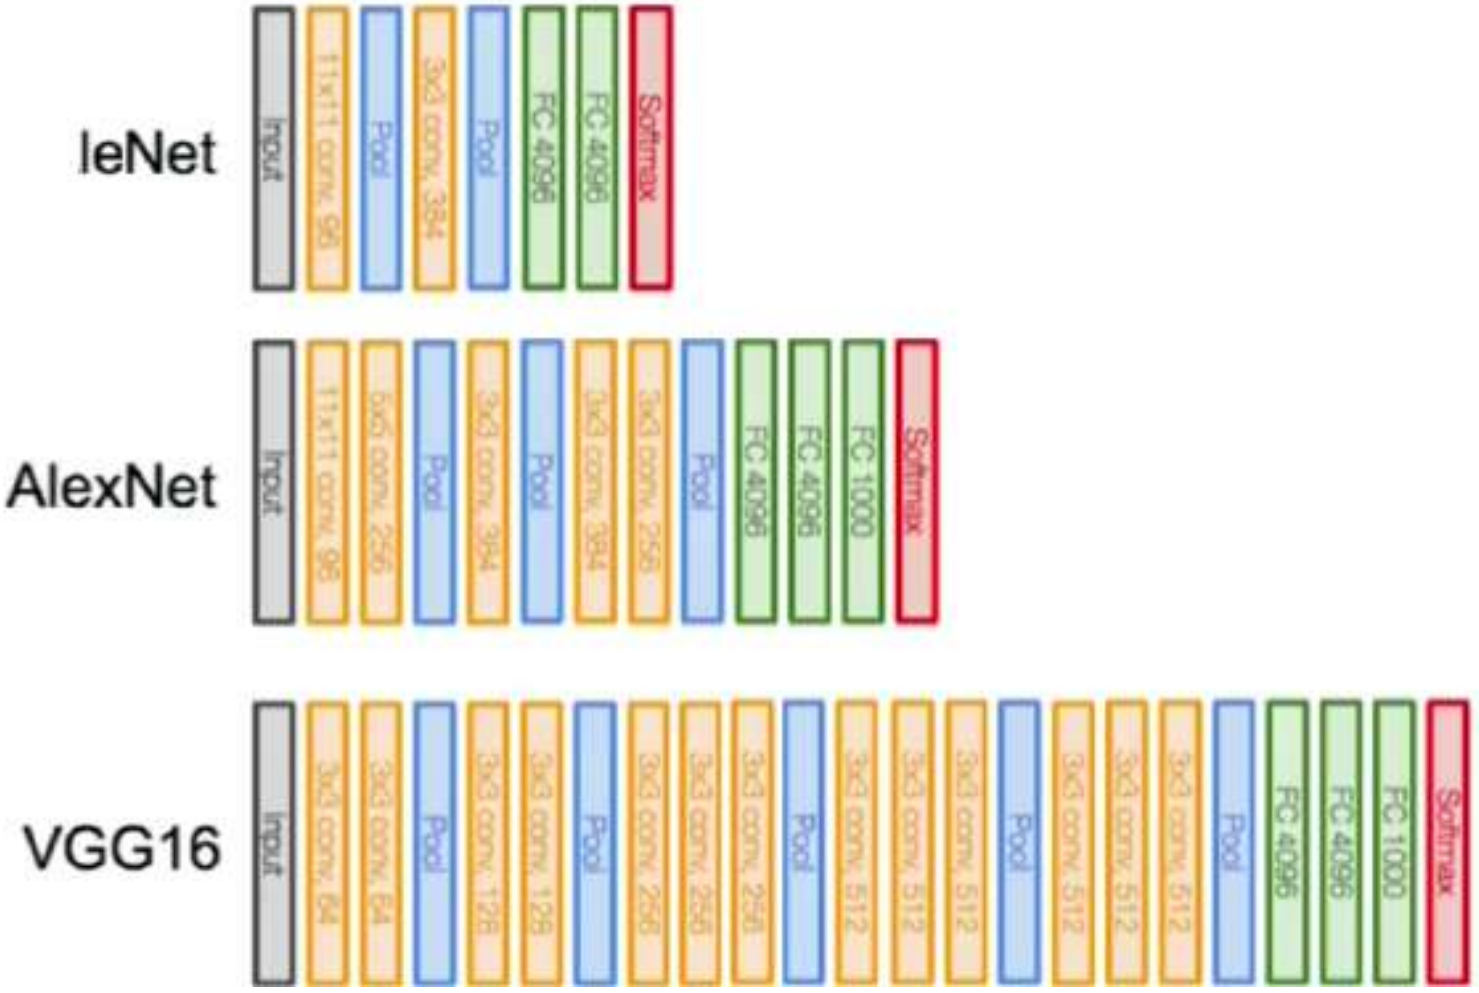

Données structurées

VGG, Resnet

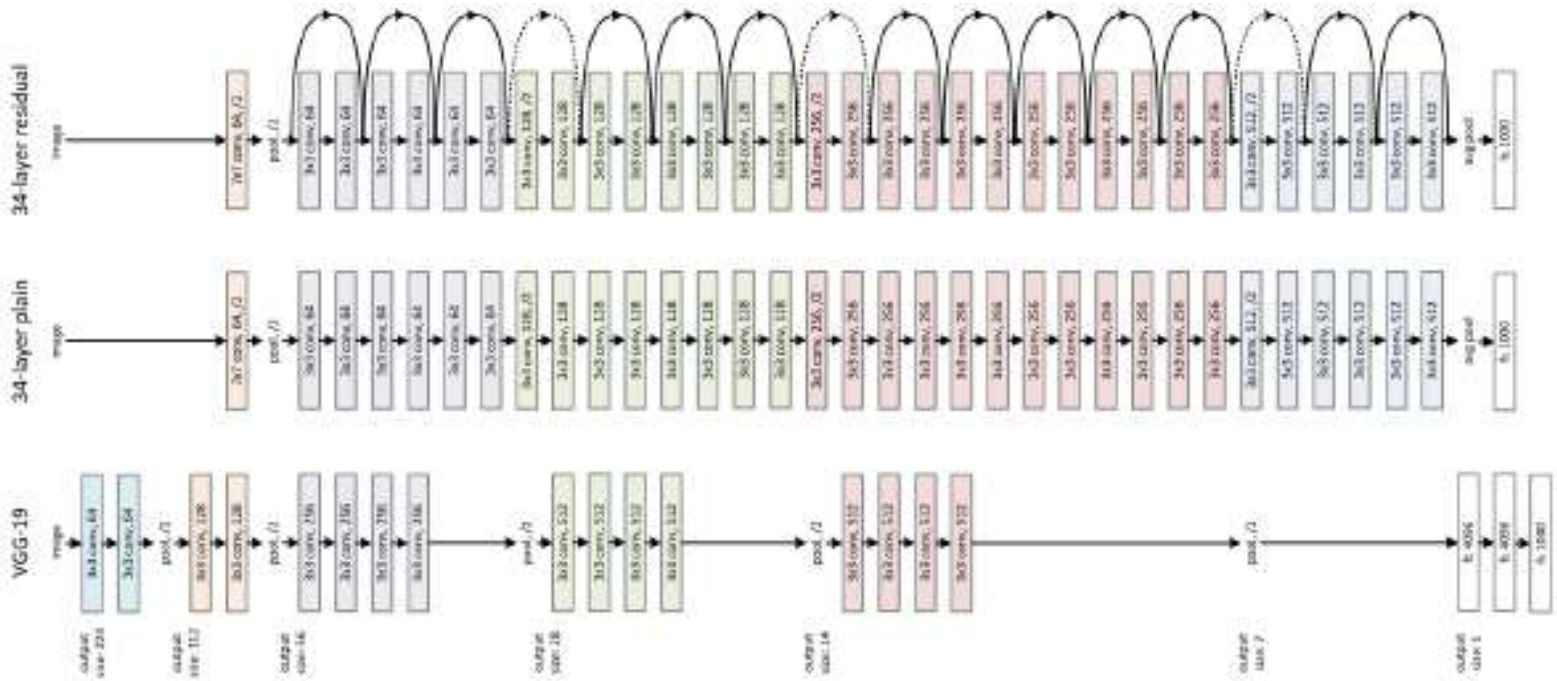

problème structurées

segmentation sémantique ?

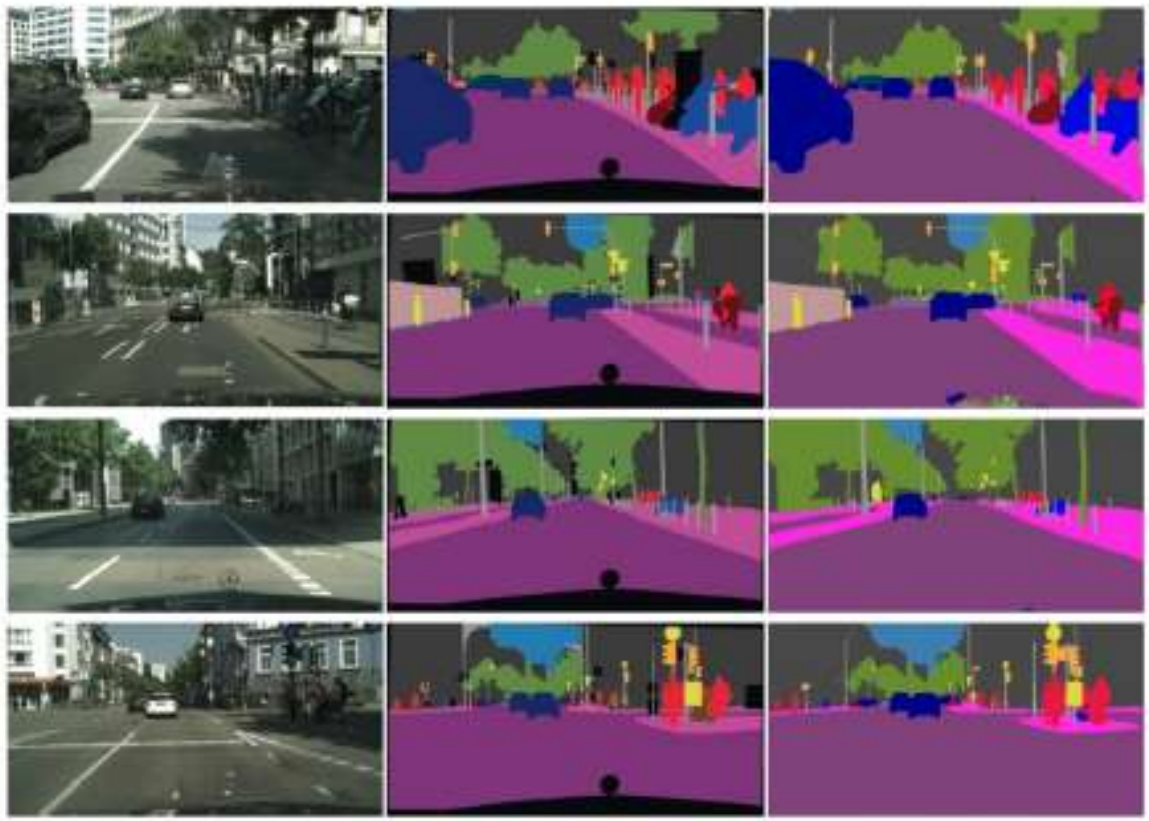

segmentation sémantique

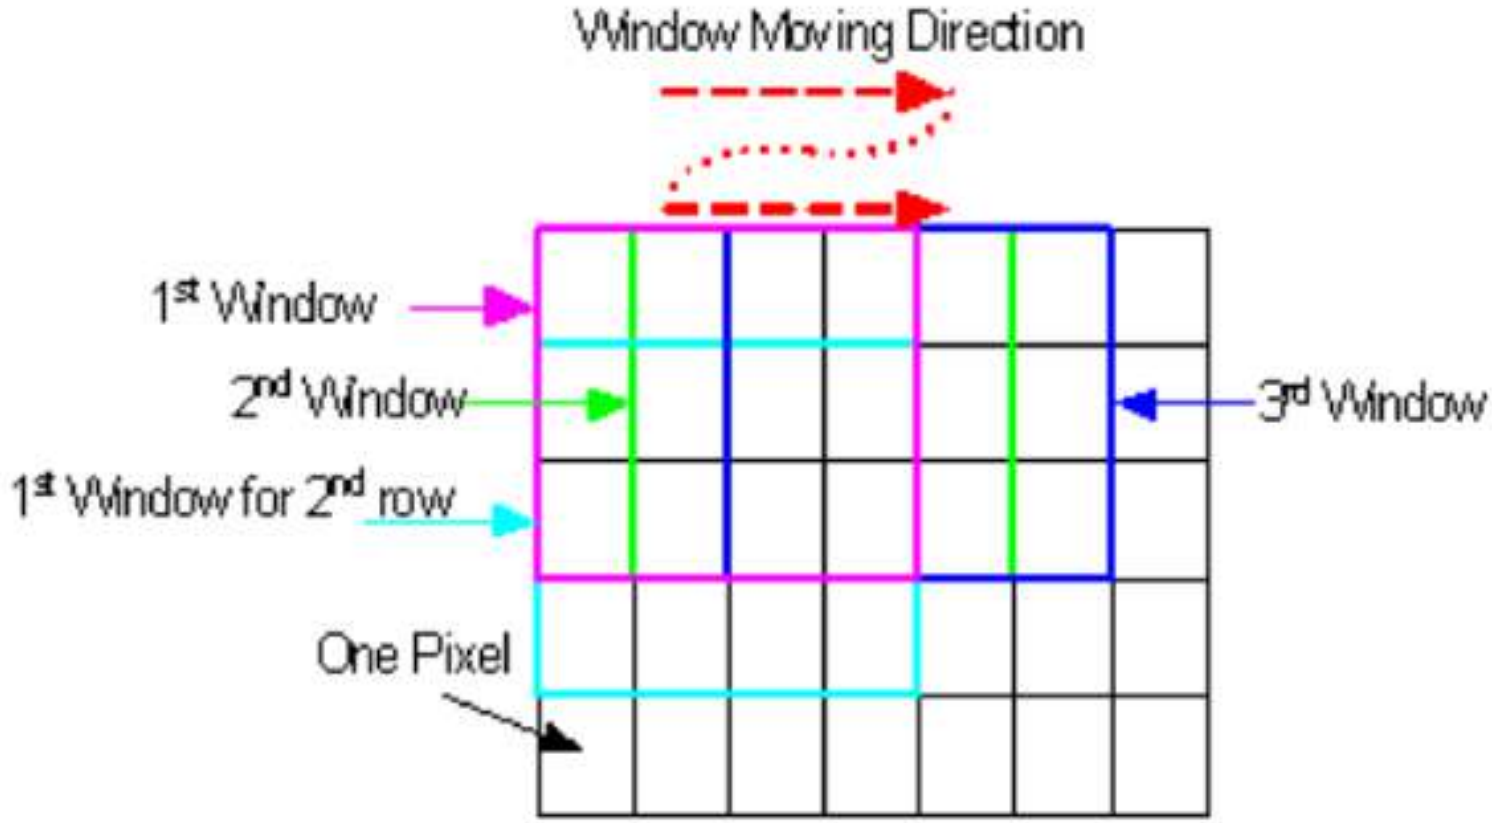

raisonner par fenêtre est une mauvaise idée : il faut raisonner par couche !

segmentation sémantique

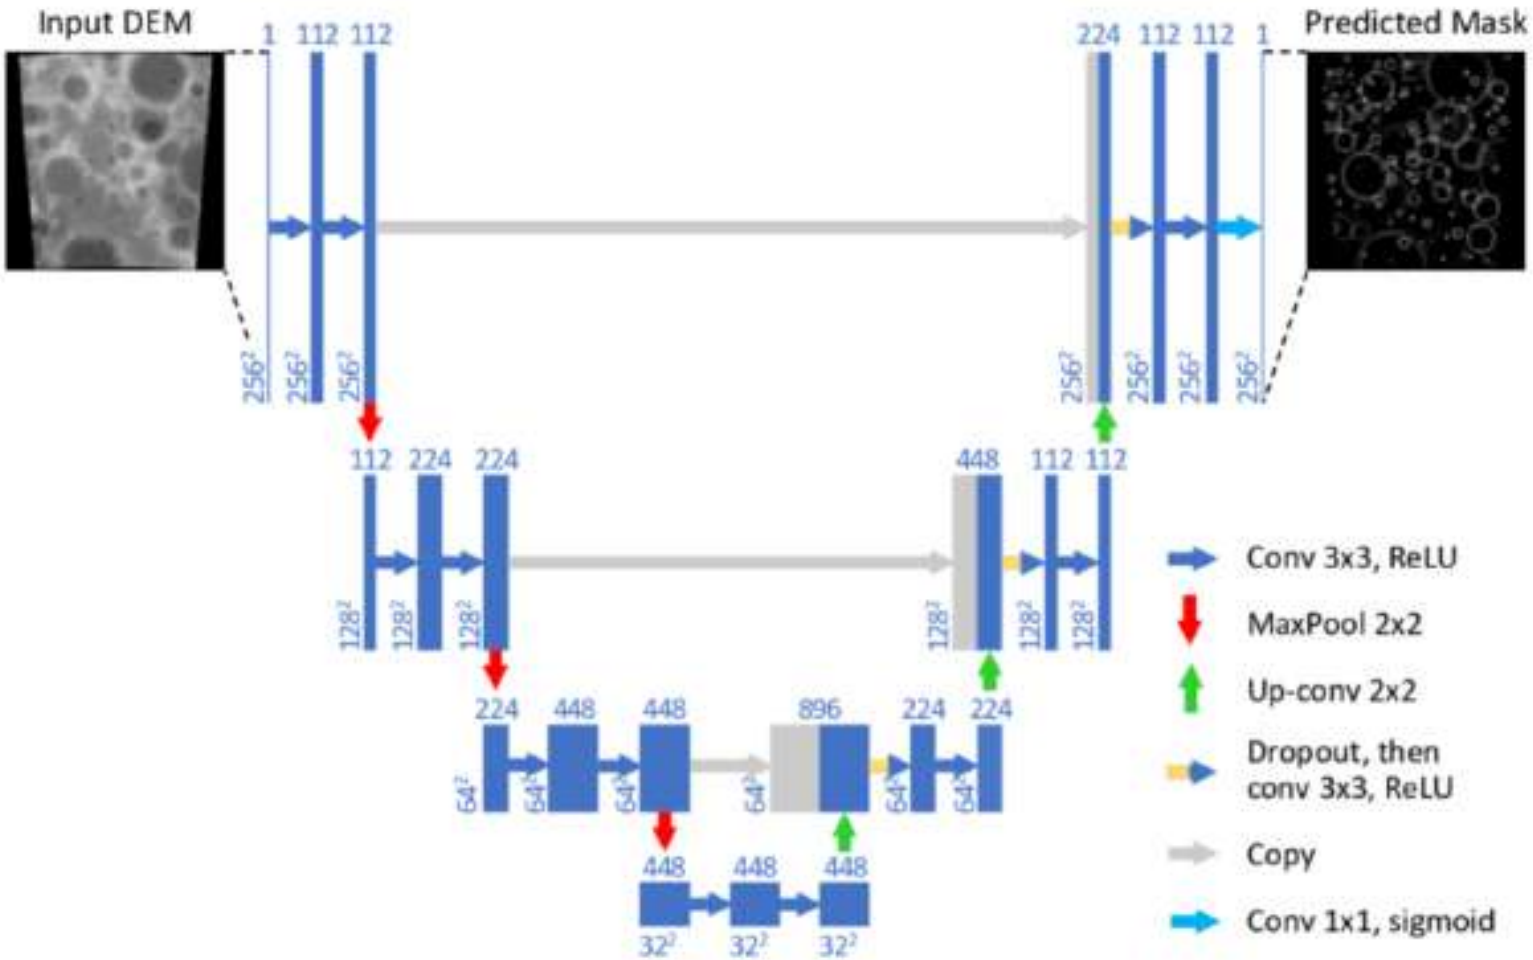

segmentation sémantique : 2 phases aussi

Apprentissage

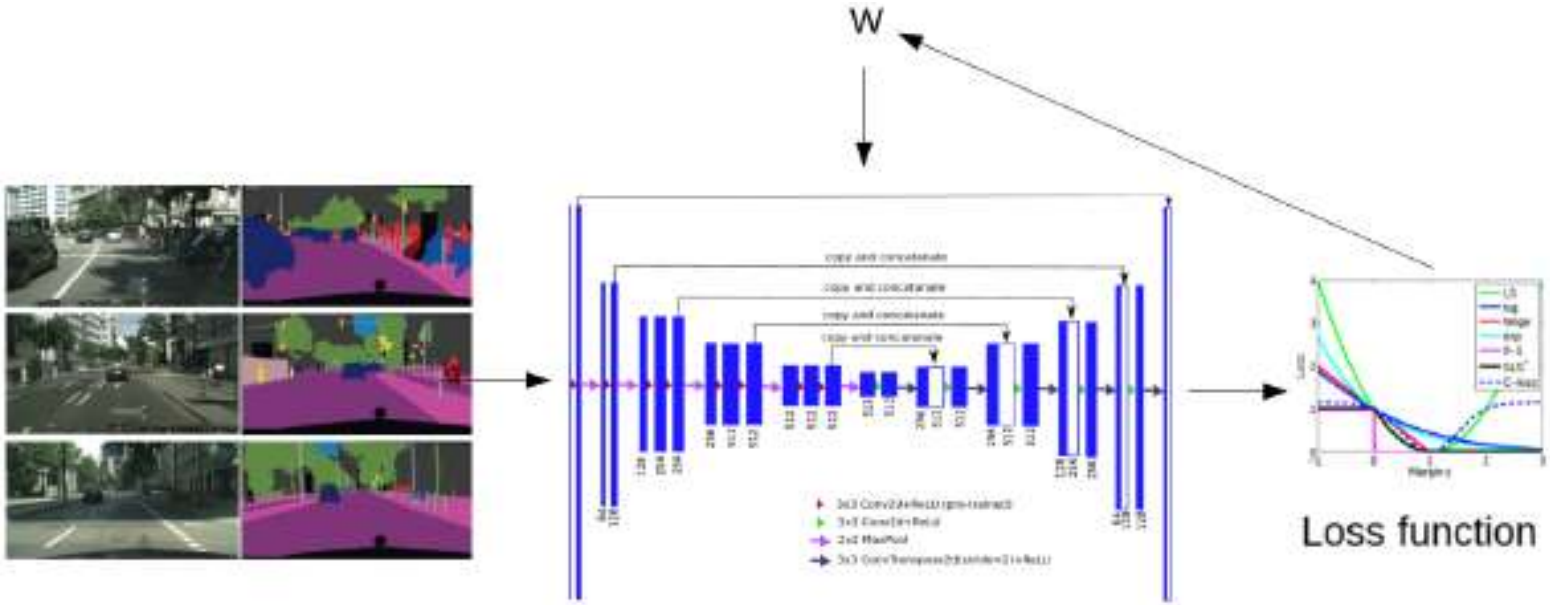

segmentation sémantique : 2 phases aussi

Test

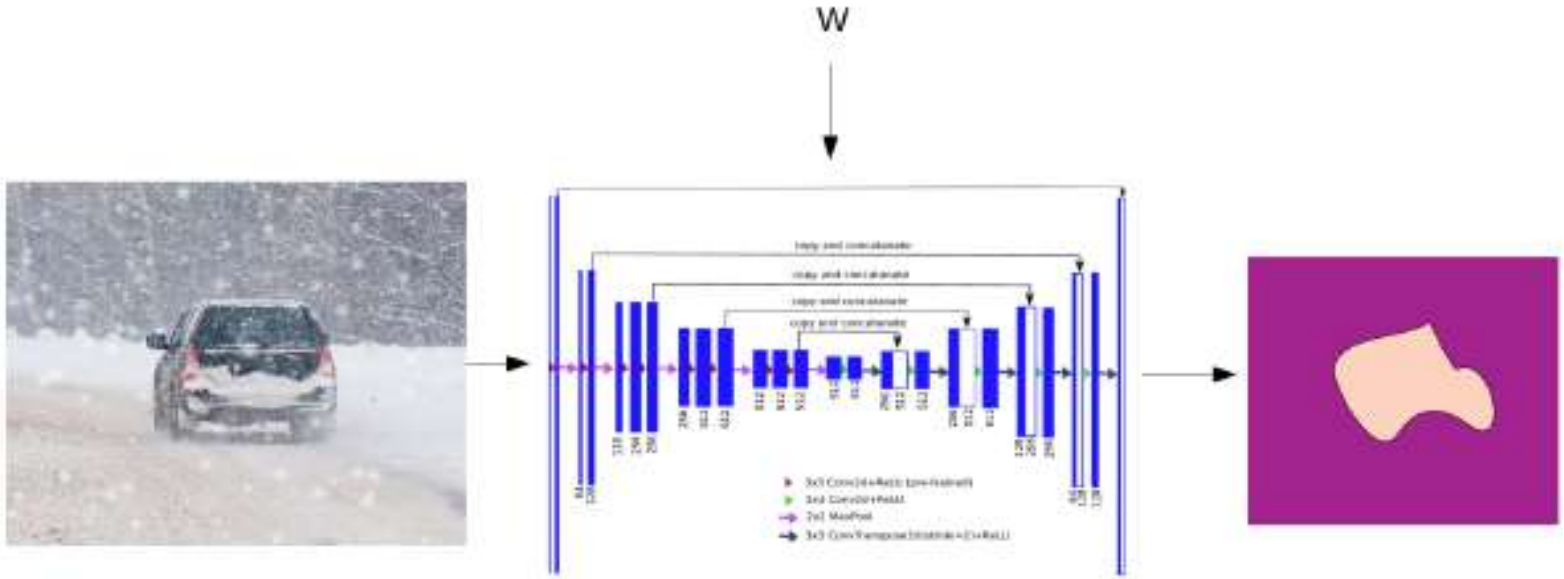

Le deep learning est incontestablement l'état de l'art sur les données/problèmes structurées
(son, image, vidéo, texte, détection, segmentation, génération...)

Disclaimer

Attention

Le mieux, ça veut pas dire que *ça marche parfaitement* !
D'ailleurs, quand on a vraiment pas beaucoup de données sur des problèmes vraiment très compliqués c'est encore limite...

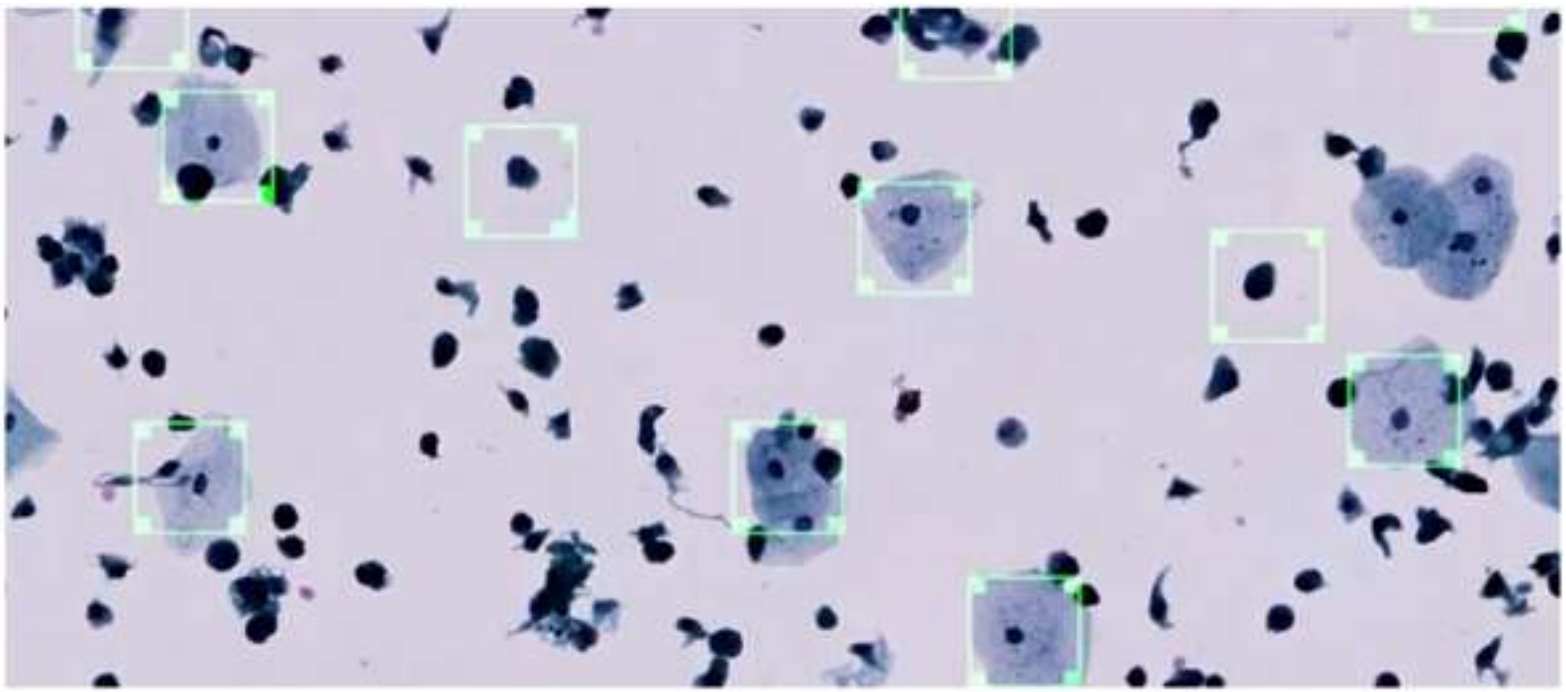

Grande dimension et instabilité

Exemple adversaire

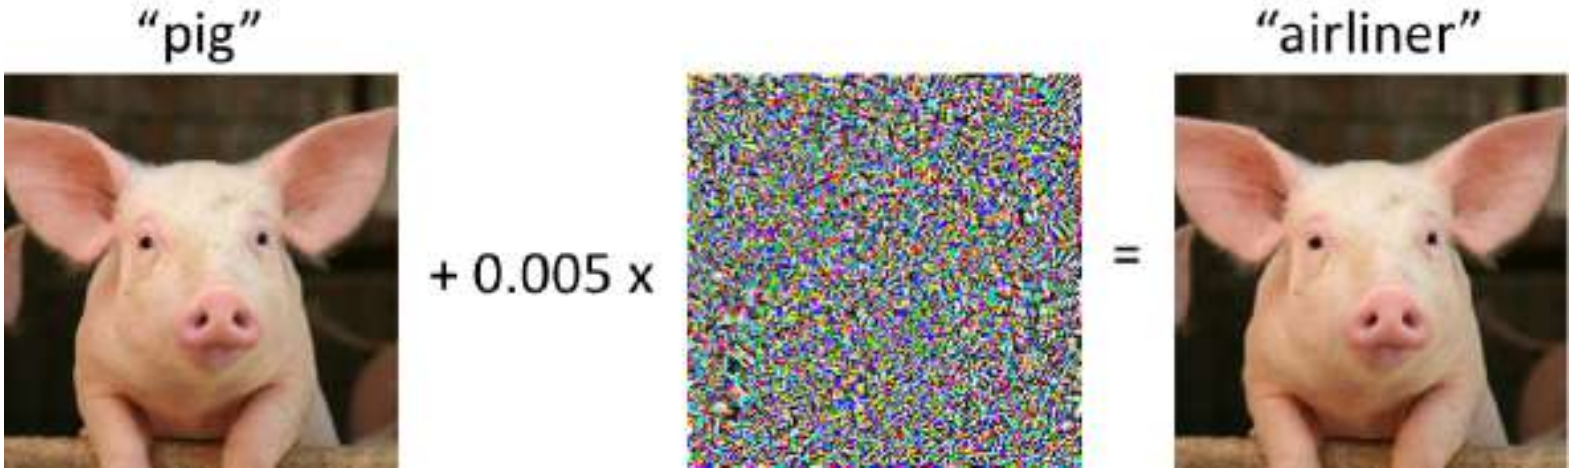

Les réseaux de neurones sont sensibles à des perturbations invisibles à l'oeil !

Grande dimension et instabilité

Exemple adversaire

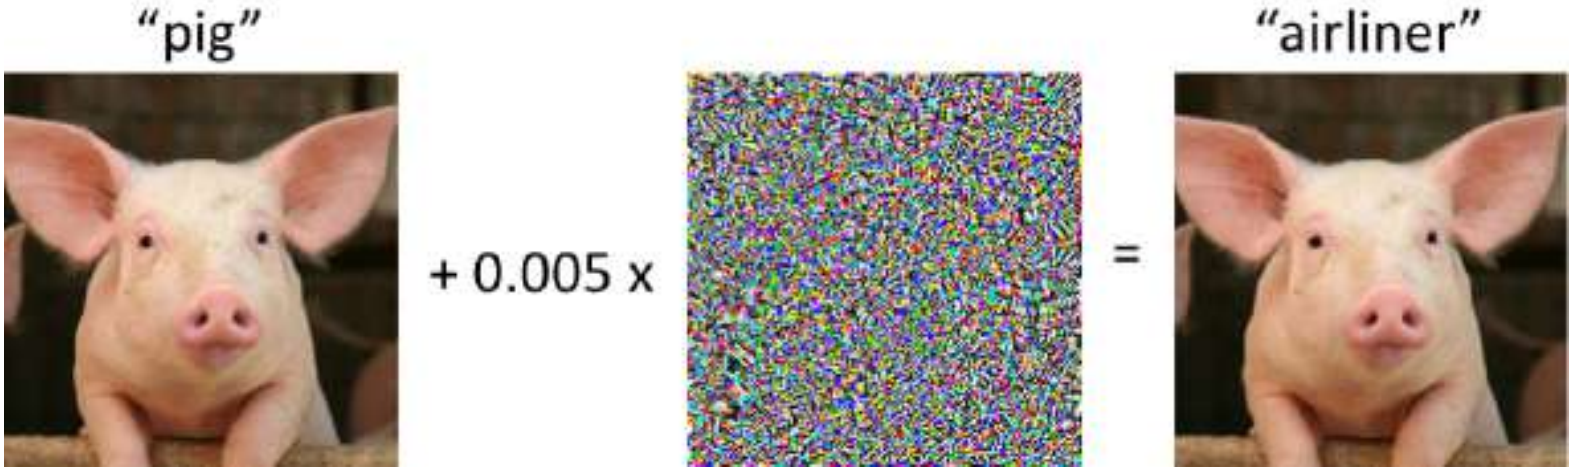

Les réseaux de neurones sont sensibles à des perturbations invisibles à l'oeil !

En réalité, c'est pas clair que ce soit grave car ces perturbations ne pas forcément réalisable physiquement

(et qu'il y a toute une communauté qui crée des défenses quand bien même ça servirait à rien).

Grande dimension et instabilité

Exemple adversaire

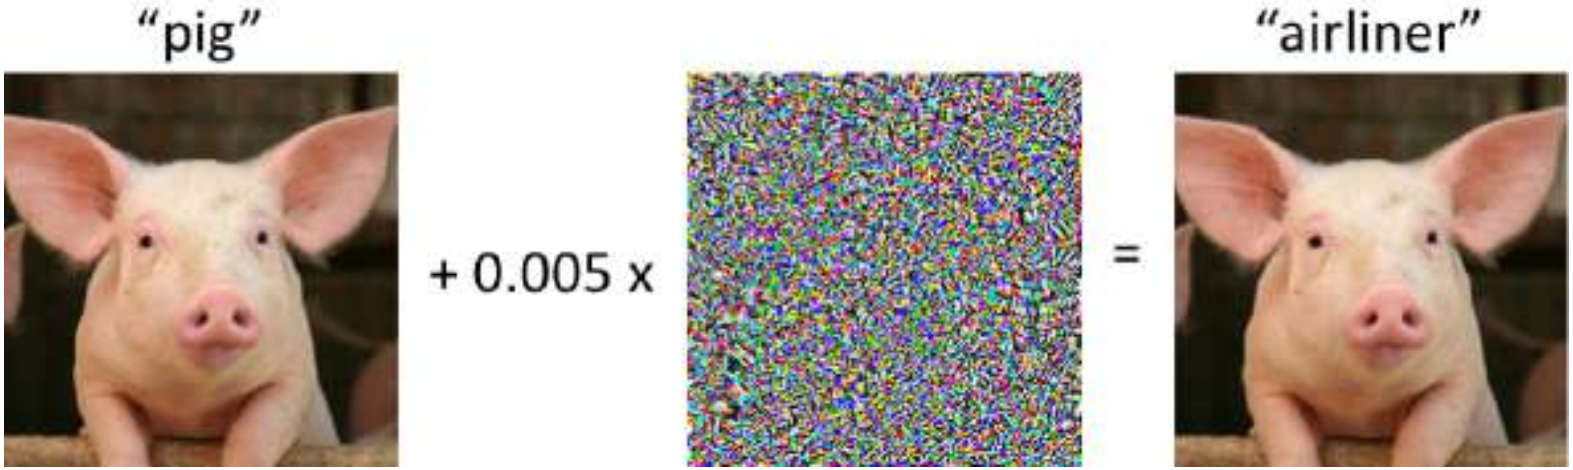

Les réseaux de neurones sont sensibles à des perturbations invisibles à l'oeil !

En réalité, c'est pas clair que ce soit grave car ces perturbations ne pas forcément réalisable physiquement

(et qu'il y a toute une communauté qui crée des défenses quand bien même ça servirait à rien).

Grande dimension et instabilité

Pourquoi ?

L'apprentissage consiste à calculer

$$\nabla_w loss(y_n, f(x_n, w))$$

et à **actualiser** w de sorte que

$$loss(y_n, f(x_n, w)) \approx 0$$

Grande dimension et instabilité

Pourquoi ?

Mais avec le même outils, on peut calculer

$$\nabla_x loss(y_n, f(x_n, w))$$

et **actualiser** x_n de sorte que

$$loss(y_n, f(x_n, w)) \gg 0$$

Grande dimension et instabilité

Pourquoi ?

Mais avec le même outils, on peut calculer

$$\nabla_x loss(y_n, f(x_n, w))$$

et **actualiser** x_n de sorte que

$$loss(y_n, f(x_n, w)) \gg 0$$

$\Rightarrow$ ce qui permet de construire une image x_n spécifiquement perturbée pour échapper au réseau : *adversarial exemple*.

Grande dimension et instabilité

Rendre les réseaux robustes

- f un réseau binaire
- Ce qu'on ne veut pas c'est $f(x) > 0$ et $f(x + delta) < 0$ (ou l'inverse) sur le testing set
- on veut donc apprendre au réseau à considérer que x est bien classé
  - non pas si $f(x) > 0$
  - mais si $f(x + \delta) > 0$ (avec $||\delta|| < \epsilon$)

Grande dimension et instabilité

Rendre les réseaux robustes

- f un réseau binaire
- Ce qu'on ne veut pas c'est $f(x) > 0$ et $f(x + delta) < 0$ (ou l'inverse) sur le testing set
- on veut donc apprendre au réseau à considérer que x est bien classé
  - non pas si $f(x) > 0$
  - mais si $f(x + \delta) > 0$ (avec $||\delta|| < \epsilon$)

$\Rightarrow$ comme ferait le SVM

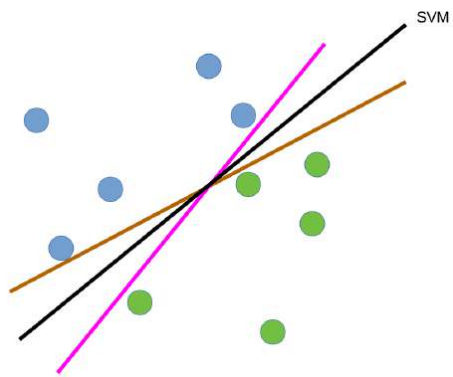

Grande dimension et instabilité

Rendre les réseaux robustes

Sauf que calculer la marge c'est NP complet pour des réseaux relu !

Grande dimension et instabilité

Rendre les réseaux robustes

2 options

- adversarial training (sous estimé le déplacement maximal)
- construction d'une enveloppe convexe (sur estimation du déplacement maximal)

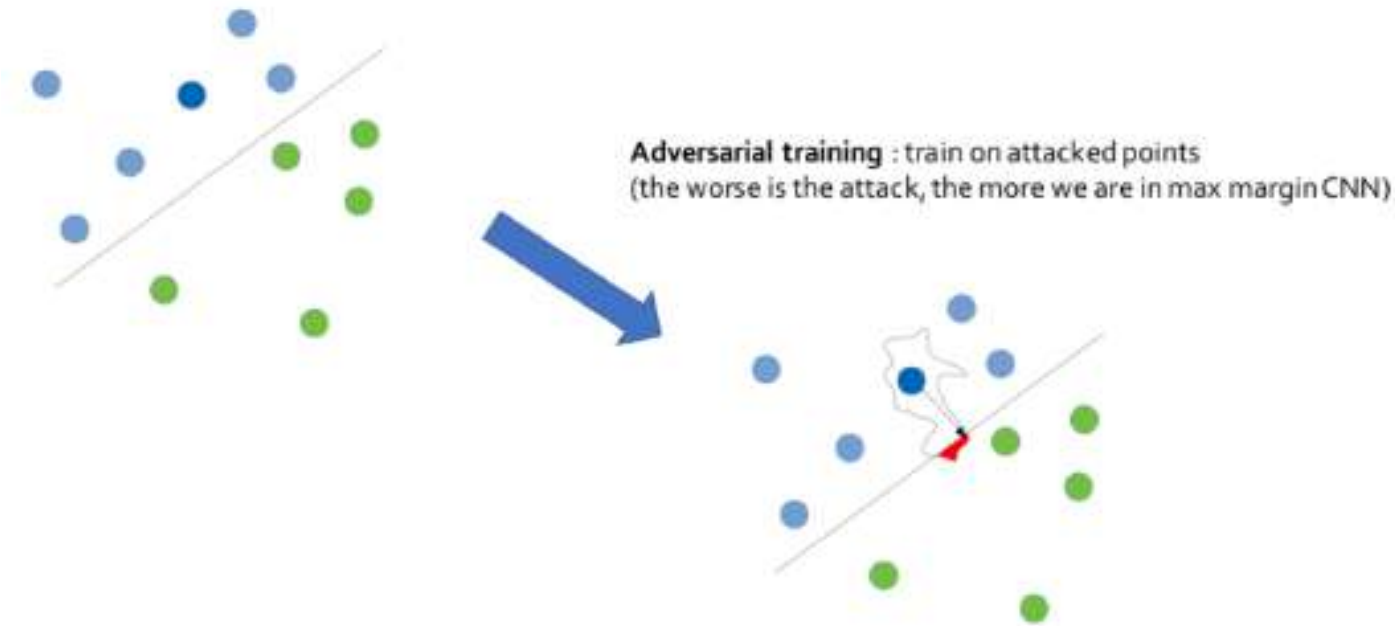

Grande dimension et instabilité

Rendre les réseaux robustes

2 options

- adversarial training (sous estimé le déplacement maximal)
- construction d'une enveloppe convexe (sur estimation du déplacement maximal)

provable defenses against adversarial examples via the convex outer adversarial polytope

Grande dimension et instabilité

Rendre les réseaux robustes

Ou tenter des réseaux Lipschitz

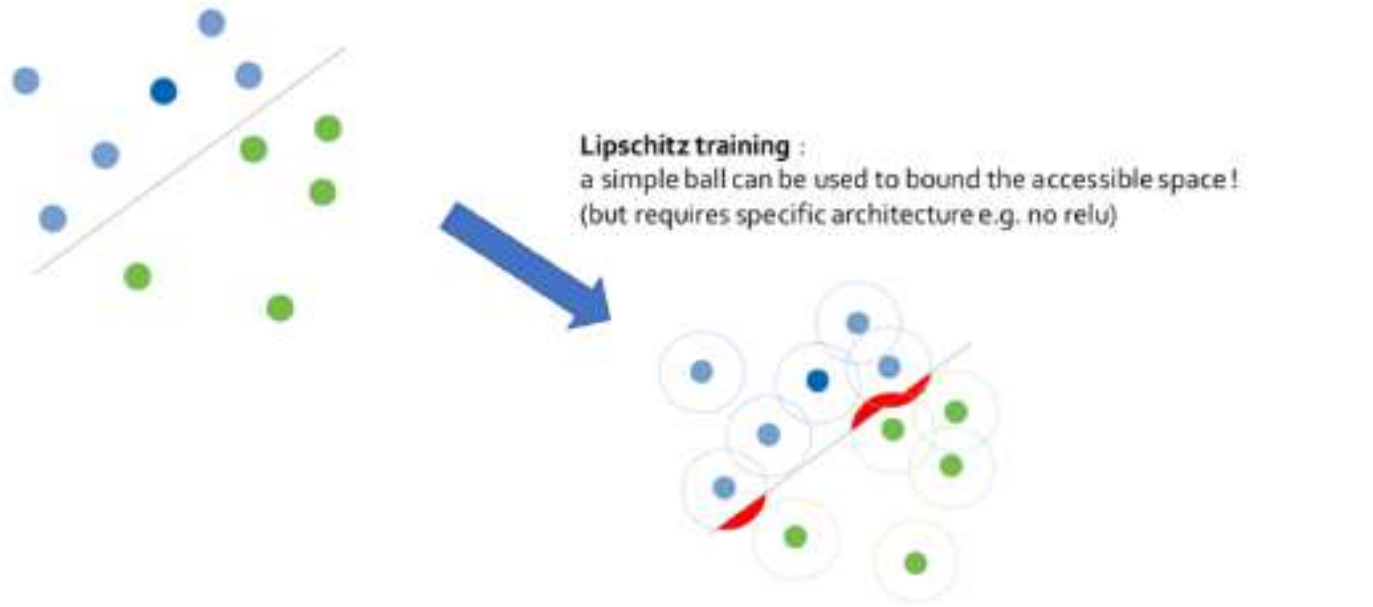

Sorting Out Lipschitz Function Approximation

Grande dimension et instabilité

MinMax

$$relu \begin{pmatrix} a \\ b \\ c \\ d \end{pmatrix} = \begin{pmatrix} \max(0,a) \\ \max(0,b) \\ \max(0,c) \\ \max(0,d) \end{pmatrix}$$

(les valeurs n'augmentent pas mais elles peuvent diminuer)

$$MinMax \begin{pmatrix} a \\ b \\ c \\ d \end{pmatrix} = \begin{pmatrix} \max(a,b) \\ \max(c,d) \\ \min(a,b) \\ \min(c,d) \end{pmatrix}$$

(les valeurs ne changent, les places changent !)

Grande dimension et instabilité

MinMax

$$MinMax\begin{pmatrix} a \\ 0 \\ b \\ 0 \end{pmatrix} = \begin{pmatrix} \max(0,a) \\ \max(0,b) \\ \min(0,a) \\ \min(0,b) \end{pmatrix} = \begin{pmatrix} relu\begin{pmatrix} a \\ b \end{pmatrix} \\ -relu\begin{pmatrix} -a \\ -b \end{pmatrix} \end{pmatrix}$$

MinMax est aussi expressif que Relu en théorie
Mais l'activation est repoussée dans la partie linéaire pour permettre un meilleur contrôle du coefficient de Lipschitz !

Grande dimension et instabilité

Rendre les réseaux robustes

Encore une fois une grosse prime à la puissance.
(Les méthodes type enveloppe sont hyper consommatrice en puissance de calcul.)

Conclusion

Divers

- un écosystème très ouvert
- tiré par les GAFAM et certains états (US, Chine)
- une technologie très égalisante
- avec une grosse prime à la puissance

Conclusion

Les axes de recherche aujourd'hui

- frugal learning : apprendre avec peu de données
- incremental learning : Apprentissage de nouvelles classes à la volé
- fairness, privacy preserving : Apprentissage éthique
- robustness : on en a parlé (tempête dans un verre d'eau)
- explainability : Apprentissage et langage
- physically informed neural network : Apprentissage hybride
- self supervised learning, representation learning : Apprentissage de représentation
- transfert learning : Adaptation de domaine

Conclusion

Les axes de recherche aujourd'hui

- frugal learning : apprendre avec peu de données
- incremental learning : Apprentissage de nouvelles classes à la volé
- fairness, privacy preserving : Apprentissage éthique
- robustness : on en a parlé (tempête dans un verre d'eau)
- explainability : Apprentissage et langage
- physically informed neural network : Apprentissage hybride
- self supervised learning, representation learning : Apprentissage de représentation
- transfert learning : Adaptation de domaine

Mais le problème de la généralisation n'est PAS réglé ! (même avec la double descente)

Conclusion

Les axes de recherche aujourd'hui

- frugal learning : apprendre avec peu de données
- incremental learning : Apprentissage de nouvelles classes à la volé
- fairness, privacy preserving : Apprentissage éthique
- robustness : on en a parlé (tempête dans un verre d'eau)
- explainability : Apprentissage et langage
- physically informed neural network : Apprentissage hybride
- self supervised learning, representation learning : Apprentissage de représentation
- transfert learning : Adaptation de domaine

Mais le problème de la généralisation n'est PAS réglé ! (même avec la double descente)
C'est aussi un problème industriel de collecte de données !

Conclusion

La généralisation

→ **c'est un problème d'apprentissage mais aussi d'industrialisation de la collecte de données**

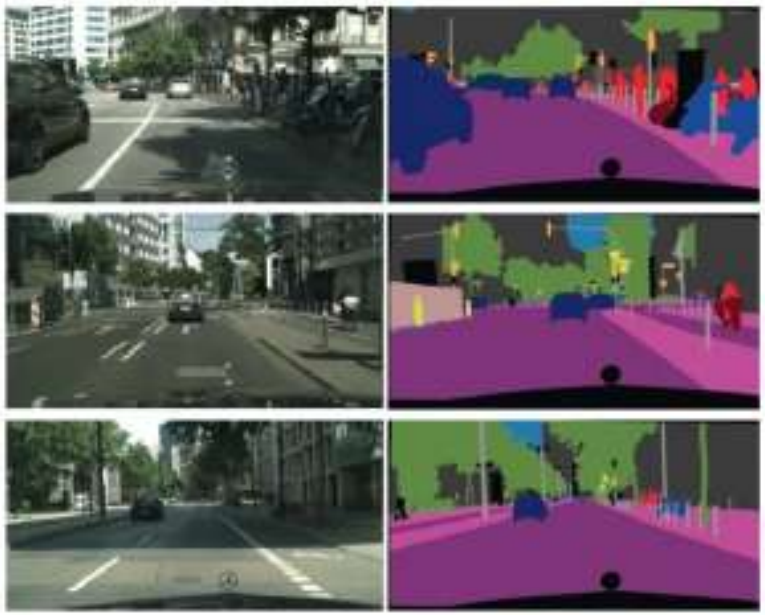

Conclusion

La généralisation

→ **c'est un problème d'apprentissage mais aussi d'industrialisation de la collecte de données**

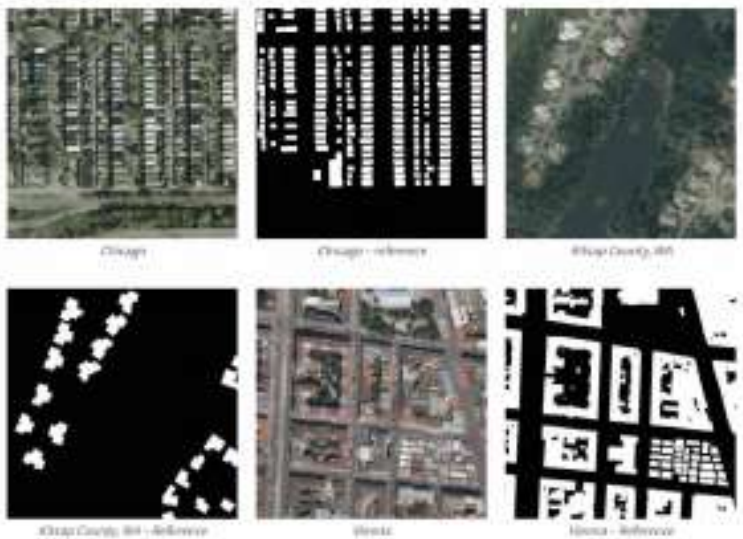

Inria Aerial Dataset : 6 villes

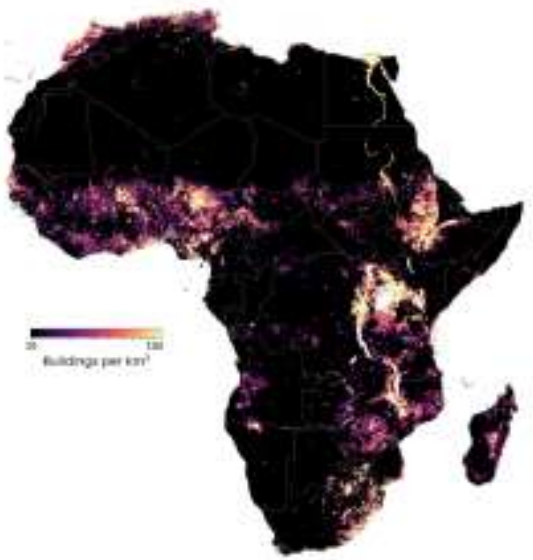

Open building dataset : l'Afrique en entier

Conclusion

Message to take home

- D'abord apprentissage puis test sur d'autres données
- Et ce qui compte c'est la performance en test !
- Réseau de neurones = couches « linéaire + activation »
- Apprentissage avec SGD
- Le deep learning est surtout pertinent sur les données structurées
- Il ne souffre pas trop d'overfitting mais nécessite beaucoup de réglage
  $\Rightarrow$ prime à la puissance de calcul

TP

- https ://playground.tensorflow.org pas d'overfitting observé
- Notebook python CIFAR10 et influence du learning rate

Questions ?